

結合擴散模型與決策樹 以高效率生成未來任意時刻大範圍人群分布

A Hybrid Framework Integrating
Diffusion Models and Decision Trees
for Efficient Generation of Large-Scale Human Mobility Patterns

報告者: 蔡季憲

指導教授: 陳奕中 老師

Outline

1 緒論

2 文獻探討

3 資料集介紹


4 研究方法

5 實驗模擬

6 結論

緒論 Introduction


- 研究背景
- 研究目的
- 過往研究
- 研究限制
- 研究貢獻



- 台灣人口稠密
- 平時若能掌握人群分布，則可緩解交通堵塞問題
- 為應對重大災害的發生，更需要透過大範圍且有效率的模擬來降低生命、財產的損失

長時間未來的人群分布

以各式條件(氣象、平假日、事件)模擬未來某時刻之情形



緒論 Introduction

- 研究背景
- 研究目的
- 過往研究
- 研究限制

過往產生人群分布方法之問題

未區分影響因子

GAN的不穩定性



精準度與計算成本

未區分影響因子

過往研究針對**大區域**產生人群分佈




大區域範圍內，可能有太多不同影響因子




未區分影響因子

- 天氣為夜市商圈的重要影響因子
- 但對於交通樞紐的影響甚小

晴天人群分布(示意)




雨天人群分布(示意)



未區分影響因子

事件因子的影響

(6月, 星期五, 晚上, 晴天)



一般情況


1000人

生成資料




2000人

演藝活動

4000人




只考慮天氣及時間因素
產生的人群分布



GAN的不穩定性


同時訓練生成器與判別器，
難以收斂



GAN的不穩定性

模式崩潰Mode Collapse


Generated
Distribution



Data
Distribution



精準度與計算成本




以深度學習對全城市人流預測方法


以單一模型預測

各區域各自建模

以單一模型預測



全城市人流時間序列




僅訓練
單一深度學習模型




各區域皆以同模型
預測未來人流量

以單一模型預測




台北市人群分佈網格






因各區域有各種**不同特性**
導致模擬結果**精確度低下**

各區域各自建模



全城市人流



計算成本非常之高
每個區域都建立一個
難以達成即時模擬
深度學習模型來預測
容易忽略空間關係

緒論 Introduction

- 研究背景
- 研究目的
- 過往研究
- 研究限制

提出概念

未區分影響因子



影響因子分群

GAN的不穩定性



Diffusion Model

精準度與計算成本




樹狀擴散模型框架

概念一:影響因子分群

- 分群


1. 利用LightGBM模型快速計算出每個網格最重要因子
2. 以split gain最高的特徵將各個網格分群



概念二: Diffusion Model

- 用較易訓練的擴散模型取代


1. GAN: 需要同時訓練雙模型，因此難以收斂，且容易產生模式崩塌的問題
2. Diffusion Model: 僅須透過不斷加噪及去噪的過程，讓模型學會識別噪音



概念三:樹狀擴散模型

- 決策樹狀的擴散模型框架

1. 預訓練: 先針對整個城市的人流分布進行訓練，並將此模型作為骨幹
2. 遷移學習: Branch與Leaf模型都是從Root遷移
3. 輕量化: 在此架構下實現簡化模型深度、輸入通道，大幅提升整體模型訓練與推論的效能



4. 異質性情境生成: 可透過各個 Leaf Model ,
在同一張地圖上模擬不同區域發生的異質性事件。
5. 特殊事件的有效訓練: 透過預訓練與遷移學習, Leaf Model
繼承了通用的圖像生成知識, 難以獨立建模的特定情境, 也
能夠被成功地訓練與模擬

緒論 Introduction

- 研究背景
- 研究目的
- 過往研究
- 研究限制

研究限制

1. 無法考慮未發生過的影響因子
2. 擴散模型常用評估指標不適合人流應用(如IS)
3. 樹狀架構的深度受限於歷史資料筆數與分布

文獻回顧Literature

資料集介紹Dataset

- 主要資料
 - 人群資料
- 輔助資料
 - 天氣資料
 - 日曆資料

台北真實電信資料集

時間：2018-01-01 ~ 2019-12-31

資料間隔：每小時一筆

範圍：


- 經度：121.46 ~ 121.665
- 緯度：24.965 ~ 25.21

資料筆數：17520小時



資料範例：

時間	(121.54, 25.165)	(121.545, 25.16)	(121.49, 25.155)	(121.54, 25.155)
2018/1/1 00:00	80	46	91	176
2018/1/1 01:00	73	44	58	169
2018/1/1 02:00	71	44	42	161
2018/1/1 03:00	71	36	40	160



交通部氣象署資料

時間：2018-01-01 ~ 2019-12-31

資料間隔：每小時一筆

資料數量：17520

特徵數量：16



特徵說明：

Feature	Unit
StnPres(測站氣壓)	hPa
SeaPres(海平面氣壓)	gpm
Temperature(氣溫)	°C
Td dew point(露點溫度)	°C
RH(相對溼度)	%
WS(風速)	m/s
WD(風向)	degree
WSGust(最大陣風)	m/s

Feature	Unit
WDGust(最大陣風風向)	degree
Precp(降水量)	mm
PrecpHour(降水時數)	hour
SunShine(日照時數)	hour
GloblRad(全天空日射量)	MJ/m ²
Visb(能見度)	km
UVI(紫外線指數)	number
Cloud(總雲量)	0~10

資料範例：

觀測時間 (hour)	測站氣壓 (hPa)	海平面氣壓 (hPa)	...	紫外線指數	總雲量 (0~10)
ObsTime	StnPres	SeaPres	...	UVI	Cloud Amount
1	1011.4	1015	...	5	3
2	1010.7	1014.3	...	7	0
...	...	...	...	...	...
24	1009.5	1013.1	...	0	10


行政機關辦公日曆表

[...](#) [資料集](#) [資料故事館](#) [互動專區](#) [消息專區](#) [諮詢小組](#)

中華民國政府行政機關辦公日曆表

中華民國政府行政機關辦公日曆表(含google日曆格式)

評分此資料集：



平均 4.33 (40 人次投票)

瀏覽次數: 36631 下載次數: 12567 意見數: 27

主要欄位說明

*粗體欄位為資料標準欄位

西元日期、星期、是否放假、備註

資料資源下載網址



CSV

[檢視資料](#) 106年中華民國政府行政機關辦公日曆表

西元日期	星期	是否放假	備註
20180101	一	1 (放假)	開國紀念日
20180102	二	0 (沒放假)	
20180103	三	0	
20180104	四	0	
20180105	五	0	
20180106	六	1	
...	...	...	...
20191231	二	0	

小巨蛋節目資訊

小巨蛋官網網頁爬蟲



台北小巨蛋
TAIPEI ARENA

臺北捷運公司 北捷遊憩公司 網站導覽 English 客服信箱 常見問答 陳情系統

熱門關鍵字： 請輸入關鍵字 進階

關於小巨蛋
我們的服務
展演活動資訊
公益檔期資訊
吃喝玩樂在巨蛋
冰上樂園
場館場地服務
申請案件
優惠資訊

首頁 > 展演活動資訊 > 節目資訊 > 歷年節目查詢


歷年節目查詢

編號	標題	發布日期
1	2025/07/05《2025CTC世界盃國際標準舞公開賽》	114-07-05
2	2025/06/28《第36屆流行音樂金曲獎頒獎典禮》	114-06-28
3	2025/06/21《2025hito流行音樂獎頒獎典禮》	114-06-21
4	2025/06/13、06/14、06/15《伍佰 & China Blue Rock Star2 演唱會 台北站》	114-06-13
5	2025/06/07《彭佳慧2025演唱會》	114-06-07
6	2025/05/31、06/01《美國高空大馬戲團》	114-05-31
7	2025/05/19-05/24、05/27-05/29《2025雙北世界壯年運動會-柔道、運動舞蹈》	114-05-19

研究方法Method

- 資料前處理
- LightGBM
- Diffusion Model
- 樹狀擴散模型
- 評估指標


系統流程圖



研究方法Method

- 資料前處理
- LightGBM
- Diffusion Model
- 樹狀擴散模型
- 評估指標

系統流程圖





- 將缺值過多的座標點去除(1/10以上時間缺值)
- 風向欄位進行sin, cos轉換
- 人工標註小巨蛋活動類型(演藝活動 / 其他活動)
- 部分欄位轉換成類別特徵(事件特徵, holiday, weekday ...)



ArenaEvents,
ArenaEvents_concert...


資料標準化

Visualizing the Statistical Meaning of Scaling




匈牙利演算法

- 介紹：
 1. 是一種指派問題的最佳化演算法
 2. 找出一種一對一匹配方式，使得成本總和最小
 3. 透過遞迴的行列運算，直到找到最佳解為止
(保證能在 n^3 時間內找到最佳解)




匈牙利演算法

- 前置作業：
 1. 建立 $H \times W (20 \times 20)$ 的網格矩陣作為最終分配
 2. 解析資料集中所有經緯度欄位，並計算出地理中心
 3. 挑選離中心最近的400個座標點



匈牙利演算法


- 執行：
 1. 建立($H \times W$, $H \times W$)的成本矩陣
 2. 計算成本，成本為座標 i 到座標 j 的直線距離
 3. 執行匈牙利演算法，回傳座標與網格的最佳配對
 4. 最終將400個經緯度座標映射至 20×20 的矩陣



研究方法_{Method}

- 資料前處理
- LightGBM
- Diffusion Model
- 樹狀擴散模型
- 評估指標


- 介紹：
 1. Light Gradient Boosting Machine，
微軟為改良傳統梯度提升決策樹(GBDT)提出之高效梯度提升框架
 2. 梯度單邊採樣(GOSS)，縮減後續輪次訓練集
 - 保留梯度大(誤差大)的樣本，對誤差小的樣本隨機抽樣
 3. 互斥特徵捆綁(EFB)降低維度
 4. 逐葉生長(Leaf-wise) 而非Level-wise




研究方法Method


- 資料前處理
- LightGBM
- Diffusion Model
- 樹狀擴散模型
- 評估指標

DDPM



U-Net







研究方法Method


- 資料前處理
- LightGBM
- Diffusion Model
- 樹狀擴散模型
- 評估指標

系統流程圖




樹狀擴散模型之建立







全地圖決策樹

1. 使用全地圖網格訓練一個共享LightGBM模型
2. 保存其中split gain最大的決策樹
3. 決策樹中的**最大split gain**路徑將在第三部分用以**建構**樹狀擴散模型中的**Root Model** 以及 **Branch Model**



Root & Branch






網格特徵分群


1. 刪除上一步驟選出特徵，每個網格單獨執行LightGBM
2. 依照各網格**最大split gain**決策樹的根結點分群，
3. 第三階段Leaf Models一部份將依此結果進行建置







事件特徵分群

1. 僅使用類別特徵(例如holiday, weekday, 事件特徵)
2. 每個網格各自建立模型
3. 將事件特徵為重要影響因子的網格各自組成群組
4. 第三階段Leaf Models一部份，將以此結果進行建置









誤差情形分群


1. 使用B


1. $\sum_{i=1}^n$
2. $\sum_{i=1}^n$
3. $\sum_{i=1}^n$
4. $\sum_{i=1}^n$

2. 四種分











系統流程圖




ONLINE

星期五晚上小巨蛋金曲獎



ONLINE




研究方法Method

- 資料前處理
- LightGBM
- Diffusion Model
- 樹狀擴散模型
- 評估指標

比較方法

1. Leaf model 與 Baseline model:

評估比較，樹狀擴散模型是否改進模擬的精準度



2. Leaf model 與 branch model:

用以判斷分群結果，以及影響因子選擇的有效性

指標介紹

1. 平均平方誤差(MSE): 預測誤差的平方的平均值，訓練模型的主要指標
2. 平均絕對誤差(MAE): 預測誤差的絕對值的平均值，與人群同尺度，最直觀的判斷方式
3. 平均絕對百分比誤差(MAPE): 預測誤差絕對值佔真實值的百分比的平均值，不受總量體限制的評估指標
4. 對稱平均絕對百分比誤差(SMAPE): MAPE的改良版，值域在 0% 到 200% 之間
5. 標準化誤差(STDE): 自定義指標，MAE / 網格真實標準差，用來檢視結果的波動範圍
6. Fréchet Inception 距離(FID): 生成圖像品質的常用指標，評估生成圖像的保真度及多樣性

實驗模擬Simulation

- LightGBM
- Diffusion Model
- 結果比較

開發環境

軟硬體	型號/版本
作業系統	Microsoft Windows 11
GPU	NVIDIA GeForce RTX 4090
CPU	Intel i9-14900K
Python	3.9.13
CUDA	12.6
PyTorch	2.6.0

LightGBM

Diffusion Model

結果比較

參數設定

超參數	設定值
Boosting type	goss
Learning rate	0.01
Iterations	10000
Early stopping	10
leaves	31
Min data in leaf	20


LightGBM

Diffusion Model


結果比較

訓練情形

全地圖訓練曲線



單一網格訓練曲線




LightGBM

Diffusion Model

結果比較

全地圖決策樹




LightGBM

Diffusion Model

結果比較


split_gain 最佳決策樹



LightGBM

Diffusion Model

結果比較



LightGBM

Diffusion Model

結果比較

1



先找出個別特徵，
再透過特徵分群

LightGBM

Diffusion Model

結果比較

網格特徵分群




LightGBM

Diffusion Model

結果比較

網格特徵分群




規則	座標數量
總雲量 ≤ 0.0	158
紫外線指數 ≤ 0.0	62
月 == 1 2	30
最大陣風 ≤ 3.5	10
最大陣風風向 ≤ -0.7	9

LightGBM

Diffusion Model

結果比較



LightGBM

Diffusion Model

結果比較

2


從已知事件特徵
直接分群

LightGBM

Diffusion Model

結果比較

事件特徵分群




規則	座標數量
ArenaEvents	27
ArenaEvents_concert	22

LightGBM

Diffusion Model

結果比較



LightGBM

Diffusion Model

結果比較

3

先分群，
再選出群代表特徵


LightGBM

Diffusion Model

結果比較

誤差情形分群


人數誤差累計情形



LightGBM

Diffusion Model

結果比較




LightGBM

Diffusion Model

結果比較

累計標準差誤差




LightGBM

Diffusion Model

結果比較



標準差誤差 > 1
累計小時數



LightGBM

Diffusion Model


結果比較



LightGBM

Diffusion Model

結果比較



實驗模擬Simulation

- LightGBM
- Diffusion Model
- 結果比較

LightGBM

Diffusion Model

結果比較

模型參數

超參數	設定值
UNet通道數	64
時間嵌入維度	64
條件特徵維度	16
時間步長	1000

LightGBM

Diffusion Model

結果比較

訓練參數


超參數	設定值
epochs	64
Batch size	256
Drop rate	0.1
Learning rate max	0.0001
Learning rate min	1e-7
Early stopping patience	8

LightGBM

Diffusion Model

結果比較

訓練情形



- 訓練時間1~3分鐘(Baseline模型則是1.5~5分鐘)
- 推論速度約1分鐘/100樣本，即每0.5秒可模擬出複數條件的人群分布

實驗模擬Simulation

- LightGBM
- Diffusion Model
- 結果比較

LightGBM

Diffusion Model

結果比較

1

網格特徵分群

LightGBM

Diffusion Model

結果比較

Leaf1



月 == 1||2

Leaf1 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-809399.4688	-976520.9219	-1296894.813
MAE	-366.269287	-355.650147	-466.193329
MAPE (AvgGrid)	-45.604094	-107.332264	-52.050587
SMAPE (AvgGrid)	-22.071429	-18.549083	-21.503407
MAPE (Overall)	-16.933806	-18.578453	-18.334706
SMAPE (Overall)	-18.409763	-17.743543	-20.275054
STDE (AvgGrid)	-1.239387	-2.678733	-1.310391
STDE (Overall)	-0.182928	-0.303075	-0.21579
FID	-76.301249	-76.301249	-76.301249

LightGBM

Diffusion Model

結果比較



LightGBM

Diffusion Model



結果比較

Leaf1 - Branch	Full Map	Filtered	Filtered Expanded
MSE	44640.46875	-223576.5156	67773.0625
MAE	-79.42862	-314.519898	-95.131806
MAPE (AvgGrid)	-9.055584	-19.631919	-7.179862
SMAPE (AvgGrid)	-8.779065	-16.824628	-6.36843
MAPE (Overall)	-3.681096	-16.621669	-3.751543
SMAPE (Overall)	-3.373643	-14.520492	-3.379052
STDE (AvgGrid)	-0.282328	-0.645864	-0.230066
STDE (Overall)	-0.03967	-0.271922	-0.044116
FID	-14.495076	-14.495076	-14.495076

LightGBM

Diffusion Model

結果比較



LightGBM

Diffusion Model

結果比較

Leaf2



紫外線指數 > 0

Leaf2 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-39683.625	44061.57813	-62733.8125
MAE	-85.370193	-66.220581	-91.790649
MAPE (AvgGrid)	-10.192648	-14.029077	-9.863565
SMAPE (AvgGrid)	-8.296431	-8.519261	-8.154473
MAPE (Overall)	-3.532974	-2.642719	-3.646752
SMAPE (Overall)	-3.723968	-2.798701	-3.858792
STDE (AvgGrid)	-0.357819	-0.506072	-0.350142
STDE (Overall)	-0.042636	-0.031043	-0.041874
FID	-9.841076	-9.841076	-9.841076

LightGBM

Diffusion Model

結果比較




LightGBM

Diffusion Model

結果比較

Leaf2 - Branch	Full Map	Filtered	Filtered Expanded
MSE	86510.59375	80181.98438	93899.96875
MAE	-73.495819	-77.211258	-71.307999
MAPE (AvgGrid)	-7.691099	-7.845531	-7.143105
SMAPE (AvgGrid)	-8.539814	-9.095755	-7.629376
MAPE (Overall)	-3.041564	-3.081333	-2.832996
SMAPE (Overall)	-3.037067	-3.214441	-2.845868
STDE (AvgGrid)	-0.265641	-0.264152	-0.254131
STDE (Overall)	-0.036706	-0.036195	-0.03253
FID	-10.654728	-10.654728	-10.654728

結果比較



LightGBM

Diffusion Model

結果比較

2

事件特徵分群

LightGBM

Diffusion Model


結果比較

Leaf3


小巨蛋活動

Leaf3 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-986336	-652944	-1E+06
MAE	-443.514	-376.193	-443.69
MAPE (AvgGrid)	-45.079	-72.473	-53.3783
SMAPE (AvgGrid)	-25.9922	-26.7361	-26.98
MAPE (Overall)	-20.3825	-18.7325	-21.301
SMAPE (Overall)	-22.1736	-20.1985	-23.063
STDE (AvgGrid)	-1.31984	-1.9632	-1.5099
STDE (Overall)	-0.22151	-0.23643	-0.2417
FID	-87.564	-87.564	-87.564

LightGBM



Diffusion Model



LightGBM

Diffusion Model



結果比較

Leaf3 - Branch	Full Map	Filtered	Filtered Expanded
MSE	69726.91	5376.04	61157.58
MAE	-14.2657	-31.931	-17.3137
MAPE (AvgGrid)	-5.50778	-8.6634	-5.59394
SMAPE (AvgGrid)	-5.05078	-7.3686	-4.61741
MAPE (Overall)	-0.65561	-1.59	-0.8312
SMAPE (Overall)	-0.60257	-1.6042	-0.7917
STDE (AvgGrid)	-0.17087	-0.3141	-0.17921
STDE (Overall)	-0.00712	-0.0201	-0.00943
FID	-5.7641	-5.7641	-5.7641

LightGBM

Diffusion Model

結果比較



LightGBM

Diffusion Model

結果比較

Leaf4

小巨蛋演唱會

Leaf4 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-1478099.094	-1093126.713	-1004081.313
MAE	-660.532852	-662.937729	-629.392044
MAPE (AvgGrid)	-83.593407	-183.511345	-119.064287
SMAPE (AvgGrid)	-38.735371	-45.748032	-43.227356
MAPE (Overall)	-30.708395	-34.94687	-34.145357
SMAPE (Overall)	-32.791893	-37.401809	-35.129142
STDE (AvgGrid)	-2.38896	-4.167679	-2.934348
STDE (Overall)	-0.329894	-0.485414	-0.449077
FID	-104.697471	-104.697471	-104.697471

LightGBM

Diffusion Model



結果比較

Leaf4 - Branch	Full Map	Filtered	Filtered Expanded
MSE	153545.625	313.814453	38242.62891
MAE	19.795914	-8.704216	2.259002
MAPE (AvgGrid)	-2.855583	4.43339	-0.550481
SMAPE (AvgGrid)	-3.655855	-9.412825	-2.757347
MAPE (Overall)	0.920318	-0.458845	0.122556
SMAPE (Overall)	1.056055	-0.476156	0.14185
STDE (AvgGrid)	-0.093831	-0.003355	-0.054696
STDE (Overall)	0.009887	-0.006374	0.001612
FID	-5.137827	-5.137827	-5.137827

LightGBM

Diffusion Model

結果比較



LightGBM

Diffusion Model

結果比較

3

誤差情形分群

LightGBM


Diffusion Model

結果比較


Leaf5
月 ≥ 10

Leaf5 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	181558.8	-5340.7	62876.51
MAE	48.31323	-25.169	8.377182
MAPE (AvgGrid)	-2.56969	-27.352	-9.22035
SMAPE (AvgGrid)	-0.28094	-8.6372	-3.23755
MAPE (Overall)	2.146446	-8.839	0.693712
SMAPE (Overall)	2.198871	-7.5553	0.836763
STDE (AvgGrid)	-0.08726	-0.7366	-0.2937
STDE (Overall)	0.024129	-0.1242	0.006359
FID	-3.4165	-3.4165	-3.4165

LightGBM



Diffusion Model



結果比較

LightGBM


Diffusion Model

結果比較


Leaf5
月 ≥ 10

Leaf5 - Branch	Full Map	Filtered	Filtered Expanded
MSE	192485.5	-13304	65010.41
MAE	24.60658	-64.995	-13.9337
MAPE (AvgGrid)	-3.21724	-50.432	-12.0676
SMAPE (AvgGrid)	-2.18924	-8.2353	-8.8392
MAPE (Overall)	1.093213	-22.825	-1.15385
SMAPE (Overall)	1.284616	-15.05	-0.91938
STDE (AvgGrid)	-0.10171	-1.3898	-0.382
STDE (Overall)	0.01229	-0.3207	-0.01058
FID	-7.9097	-7.9097	-7.9097

LightGBM



Diffusion Model



結果比較

LightGBM

Diffusion Model


結果比較

Leaf6


相對溼度 ≤ 67.5

Leaf6 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	35278.78	8155.44	18220.25
MAE	-28.5479	-25.4281	-29.266
MAPE (AvgGrid)	-7.5999	-7.78216	-9.37
SMAPE (AvgGrid)	-6.2081	-8.8053	-7.4364
MAPE (Overall)	-1.18476	-1.3155	-1.25109
SMAPE (Overall)	-1.24501	-1.3913	-1.31611
STDE (AvgGrid)	-0.24189	-0.21106	-0.2944
STDE (Overall)	-0.0143	-0.01345	-0.0134
FID	-5.8897	-5.8897	-5.8897

LightGBM



Diffusion Model



LightGBM

Diffusion Model


結果比較

Leaf6


相對溼度 ≤ 67.5

	Full Map	Filtered	Filtered Expanded
MSE	146311.3	48558.1	132210.3
MAE	-10.0055	-48.544	-14.655
MAPE (AvgGrid)	-4.54748	-15.865	-6.48271
SMAPE (AvgGrid)	-5.59885	-9.1926	-7.8195
MAPE (Overall)	-0.41524	-2.5114	-0.62648
SMAPE (Overall)	-0.39519	-2.2395	-0.6053
STDE (AvgGrid)	-0.15005	-0.4737	-0.20763
STDE (Overall)	-0.005	-0.0257	-0.00671
FID	-6.4601	-6.4601	-6.4601

LightGBM



Diffusion Model



結果比較

LightGBM

Diffusion Model

結果比較

Leaf7 台北燈節

本實驗旨在探討，當符合條件的資料筆數極少時，是否仍能有效訓練模型並進行準確推論與模擬。

LightGBM

Diffusion Model

結果比較



本研究所採用的樹狀擴散模型在模擬人群分布結果的精確度方面，顯著優於**Baseline Model**。其主要原因在於，單一擴散模型難以以極少量的資料完成有效訓練，而本研究提出的階層式架構能透過**Root Model**與**Branch Model**先行捕捉城市人群分布的大致趨勢。因而，即便最終可用的歷史資料相當稀少，仍可準確模擬出符合設定條件的人群分布情形。

	Full Map	Filtered	red Expa
MSE	-1.4E+07	-2E+07	-1.3E+07
MAE	-1929.36	-1929.6	-1903.59
PE (AvgG	-332.606	-362.12	-253.6
PE (AvgG	-71.6258	-72.573	-70.9831
PE (Over	-81.1739	-83.421	-78.4944
APE (Ove	-73.6744	-75.087	-72.8056
DE (AvgG	-9.65888	-10.134	-7.23276
DE (Over	-0.96359	-1.3876	-1.01082
FID	-107.95	-107.95	-107.95

LightGBM

Diffusion Model

結果比較



LightGBM

Diffusion Model

結果比較



在Leaf Model 7所涵蓋的區域內，Leaf Model顯著修正了Branch Model先前模擬偏差的問題；而在該區域以外的範圍，Branch Model則展現出更佳的模擬效果。這一結果顯示，本研究針對台北燈節事件因子的分群策略十分有效，所涵蓋群體中的網格整體而言對該因子展現高度敏感性。

	Full Map	Filtered	red Expa
MSE	434272.4	-43562	295660.1
MAE	94.66933	-83.758	59.35393
PE (AvgG	3.350035	-1.5837	2.692221
PE (AvgG	2.416271	-7.3177	1.828144
PE (Over	3.983013	-3.6211	2.447452
APE (Ove	3.911417	-4.2775	2.22505
DE (AvgG	0.051985	-0.1752	0.022723
DE (Over	0.047281	-0.0602	0.031517
FID	-2.7998	-2.7998	-2.7998

LightGBM

Diffusion Model

結果比較



LightGBM

Diffusion Model

結果比較

Leaf8

新北耶誕城

本實驗旨在探討，當事件發生地位於目標模擬人群分布範圍以外的城市時，模型的模擬效能表現如何。

LightGBM

Diffusion Model

結果比較



Leaf Model在多項評估結果上均大幅超越Baseline Model，顯示在面對特殊事件時，階層式擴散模型的架構有效彌補了單一模型的不足，不論事件發生地是否位於目標模擬之範圍。

	Full Map	Filtered	red Expansion
MSE	-2E+06	-670215	-1704938
MAE	-718.78	-492.012	-677.166
PE (AvgG)	-84.745	-37.2031	-77.2916
PE (AvgC)	-37.316	-32.8346	-35.2619
PE (Over)	-31.838	-25.2446	-30.2526
APE (Ove	-34.373	-26.1904	-32.6739
DE (AvgG	-2.318	-1.65452	-2.10331
DE (Over	-0.35899	-0.3908	-0.35924
FID	-130.42	-130.42	-130.42

LightGBM

Diffusion Model

結果比較



LightGBM


Diffusion Model

結果比較


修正情況最好的位置都恰好分布在**Leaf Model 8**所分群的區域內，由此可證明，儘管針對特殊事件發生於目標模擬地圖之外，本研究提出的樹狀擴散架構的分群方法依然效果顯著。

	Full Map	Filtered	red Expansion
MSE	59158.19	-41381	36646.59
MAE	-43.3911	-121.38	-58.7866
PE (AvgG)	-7.19531	-11.212	-9.36152
PE (AvgC)	-6.0631	-12.562	-6.21962
PE (Over)	-1.922	-6.2277	-2.62631
APE (Over)	-1.92147	-6.2597	-2.61768
DE (AvgG)	-0.20722	-0.407	-0.26127
DE (Over)	-0.02167	-0.0964	-0.03119
FID	-7.1142	-7.1142	-7.1142

LightGBM



Diffusion Model



結果比較

1. 樹狀擴散模型框架其模擬能力確實勝過單一擴散模型
2. 使用 LightGBM 模型對地圖進行特徵分群，以訓練專家模型的策略顯具有效性
3. 訓練資料利用效率高，僅有少量訓練資料的特殊事件，也能透過階層架構得到良好的模擬結果
4. 制定分群規模上下限規則，或動態的群組合併與拆分策略
5. 特徵存在共線性，自動化識別並篩選冗餘特徵的機制
6. 針對單一極端網格加以處理，思考一個新的加權評估指標

Thank you.