

國立中興大學資訊工程學系

碩士學位論文

結合擴散模型與決策樹以高效率生成

未來任意時刻大範圍人群分布

A Hybrid Framework Integrating Diffusion Models
and Decision Trees for Efficient Generation
of Large-Scale Human Mobility Patterns

國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

指導教授：陳奕中 Yi-Chung Chen

研究生：蔡季憲 Ji-Xian Tsai

中華民國一百一十四年八月

國立中興大學 資訊工程學系
碩士學位論文

題目：結合擴散模型與決策樹以高效率生成未來任意時刻
大範圍人群分布 A Hybrid Framework Integrating
Diffusion Models and Decision Trees for Efficient
Generation of Large-Scale Human Mobility Patterns

姓名：蔡季憲 學號：7112056073

經 口 試 通 過 特 此 證 明

論文指導教授

陳堯中

論文考試委員

邱勝和

陳堯中

吳秉昇

楊子明

中華民國 114 年 7 月 29 日

誌謝

首先要感謝我的父母，在我不斷自我懷疑時，也不會質疑放棄工作跑去考研這個魯莽決定，不干涉我的想法，讓我能無後顧之憂的堅持到最後。

碩班兩年時光中最重要的人，也就是我的指導教授 陳奕中老師，感謝您從我們還沒入學時就鼓勵我們參與各式各樣的計畫、專案與比賽，讓我們提前適應學術生活；在百忙之中不厭其煩抽空與我們討論問題，給予指導與建議，提供了我們許多受用不盡的支援，這些資源不僅僅只是在學術研究上，更對我們未來職涯發展有莫大的幫助。

感謝實驗室的支柱，揚州學長與長宏學長，不管情況多緊急都能在最後關頭即刻救援，賦閒時陪同我們一起閒聊、遊戲，抒發壓力，除此之外還提供我們投資與求職的諮商，有著說不完的感謝。除了博班學長外，還有許多已經畢業先進，善齊、亮鈞、軍磊以及其他學長姐，謝謝你們留下許多的研究能量，讓我在碩論遇到瓶頸時也能用最大的產能快速重新來過。也謝謝學弟妹們，承翰幫忙我們這屆處理很多口試的工作；瀚祺讓我碩班的最後不那麼苦悶；瑋志、証曜、博敏、泊原、季樽，實驗室因你們不再冷清，未來還要靠你們繼續努力。

最後，謝謝同期的夥伴們，昺儒憑一己之力搞定整間實驗室的硬體需求；展緯是我的標竿，學業上的事情總以他為榜樣；昱婷協助解決各種疑難雜症，拯救我於水火之中；意雯、子雁走在畢業最前線，讓我們能事先掌握可能會碰上的狀況。因為大家我才能順利畢業，感謝各位。

摘要

近年來，隨著都市化發展，大範圍的人群移動模擬對於交通管理與災害應變至為關鍵。然而，現有的深度學習方法普遍面臨一個兩難困境：採用單一通用模型，難以捕捉城市中不同區域與事件的異質性；而為各區域獨立建模，則計算成本過於高昂且忽略了空間關聯性。為解決此問題，本研究提出一個創新的「樹狀擴散模型(Tree-like Diffusion Model)」框架，旨在結合決策樹的數據劃分能力與擴散模型的強大生成能力，以高效率生成高保真度的人群分布。首先，本框架利用 LightGBM 模型對時空數據進行分析，自動找出影響人流的關鍵因子，並據此建構一個階層式的數據分群結構。接著，我們採用預訓練與遷移學習的策略：先以完整的城市數據訓練一個通用的根模型(Root Model)作為骨幹，再將其知識遷移至針對特定數據子集進行微調的分支模型(Branch Model)與葉模型(Leaf Model)。此舉大幅降低了對數據量的要求，使得那些樣本數較少、難以獨立建模的特定情境(如特殊事件)能夠被成功地訓練與模擬，顯著提升了訓練資料的利用效率。本研究以真實世界的台北市人群流動數據集進行驗證，實驗結果表明，本研究提出的樹狀擴散框架，其專家模型(Leaf Model)在各項評估指標上，均顯著優於傳統的單一擴散模型(Baseline Model)以及較為通用的上層模型(Branch Model)。此結果驗證了本框架能有效處理數據異質性，並在計算效率與模擬精度之間取得優異的平衡，為複雜的都市人群模擬任務提供了一條新的解決途徑。

關鍵字：人群分布預測、決策樹模型、擴散模型、樹狀擴散模型、遷移學習、時空資料、特徵工程

Abstract

Continual urban expansion is driving demand for simulations of crowd-movement to support traffic management and emergency response. However, these efforts are hindered by a computational dilemma, wherein single general-purpose models are unable to capture the heterogeneity across urban regions and situations, while modeling areas independently incurs high computational overhead and fails to account for spatial correlations. This study developed a novel Tree-structured Diffusion Model for the modeling of crowd distributions, integrating decision trees for data partitioning with generative diffusion models. The LightGBM model is first used to analyze spatiotemporal data to identify key factors influencing crowd flow and create an hierarchy of regions (root, branches, leaves). A diffusion model is then pretrained at the root for the dissemination of knowledge to branches and leaf models to enable fine-tuning for specific data subsets. This approach reduces the required data volumes, enabling the training and simulation of specific scenarios that would otherwise be difficult to model independently. The validity of the framework was assessed using a real-world Taipei City crowd-flow dataset. The leaf (expert) model outperformed a conventional single diffusion (baseline) model and high-level branch models across standard evaluation metrics. These findings demonstrate the efficacy of the proposed framework in managing data heterogeneity and achieving a balance between computational efficiency and simulation accuracy for complex, city-scale crowd modeling.

Keywords: Crowd Distribution Prediction, Decision Tree Model, Diffusion Model, Tree-structured Diffusion Model, Transfer Learning, Spatio-temporal Data, Feature Engineering

目次

摘要	i
Abstract	ii
目次	iii
表目次	v
圖目次	vi
第一章 緒論	1
1.1 研究背景與動機	1
1.2 研究範圍與限制	7
第二章 文獻回顧	9
2.1 人群分布影響因素	9
2.2 時空資料預測演算法	10
2.3 時空資料分群演算法	12
2.4 LightGBM	13
2.5 擴散模型	15
第三章 資料集	17
3.1 人群資料	17
3.2 輔助資料	18
3.3 資料整合與切割	21
第四章 研究方法	22
4.1 資料前處理	23
4.2 LighGBM	26
4.3 Diffusion Model	31
4.4 樹狀擴散模型	37
4.5 Online 流程	39
4.6 評估標準	41
第五章 實驗模擬	46
5.1 Diffusion Model 效能驗證	46
5.2 LightGBM 及樹狀骨幹效能驗證	48

5.3 Leaf Model 建模效能驗證	52
5.4 事件特徵分群效能驗證	68
5.5 實驗小結	73
第六章 結論	75
參考書目	77



國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

表目次

表 1、人流資料範例	17
表 2、氣象資料欄位	19
表 3、擴散模型參數表	47
表 4、擴散模型訓練參數表	47
表 5、LIGHTGBM 模型參數表	49
表 6、網格特徵分群表	54
表 7、小巨蛋活動分群表	55
表 8、LEAF MODEL 1 實驗模擬結果(LEAF1 - BASELINE)	57
表 9、LEAF MODEL 1 實驗模擬結果(LEAF1 - BRANCH)	58
表 10、LEAF MODEL 2 實驗模擬結果(LEAF2 - BASELINE)	59
表 11、LEAF MODEL 2 實驗模擬結果(LEAF2 - BRANCH)	60
表 12、LEAF MODEL 3 實驗模擬結果(LEAF3 - BASELINE)	61
表 13、LEAF MODEL 3 實驗模擬結果(LEAF3 - BRANCH)	62
表 14、LEAF MODEL 4 實驗模擬結果(LEAF4 - BASELINE)	63
表 15、LEAF MODEL 4 實驗模擬結果(LEAF3 - BRANCH)	64
表 16、LEAF MODEL 5 實驗模擬結果(LEAF5 - BASELINE)	65
表 17、LEAF MODEL 5 實驗模擬結果(LEAF5 - BRANCH)	66
表 18、LEAF MODEL 6 實驗模擬結果(LEAF6 - BASELINE)	67
表 19、LEAF MODEL 6 實驗模擬結果(LEAF6 - BRANCH)	68
表 20、LEAF MODEL 7 實驗模擬結果(LEAF7 - BASELINE)	69
表 21、LEAF MODEL 7 實驗模擬結果(LEAF7 - BRANCH)	70
表 22、LEAF MODEL 8 實驗模擬結果(LEAF8 - BASELINE)	71
表 23、LEAF MODEL 8 實驗模擬結果(LEAF8 - BRANCH)	72

圖目次

圖 1、2028/2/27 15:00 人群分布	2
圖 2、2027/8/9 08:00 人群分布	2
圖 3、2018 九合一大選與週六平均人群差異百分比	4
圖 4、台北車站周邊異質性示意圖	5
圖 5、樹狀擴散模型(DIFFUSION TREE)架構示意圖	5
圖 6、人群資料空間示意圖	18
圖 7、CODIS 查詢介面[67]	18
圖 8、小巨蛋官方網站[72]	20
圖 9、系統流程圖	23
圖 10、Z-SCORE 與 MIN-MAX 比較	24
圖 11、地理中心與篩選後座標點	25
圖 12、20x20 人群矩陣示意圖	26
圖 13、LEVEL-WISE 示意圖	27
圖 14、LEAF-WISE 示意圖	27
圖 15、全地圖特徵決策樹(局部)	28
圖 16、網格特徵分群結果示意圖	29
圖 17、事件特徵分群結果示意圖	30
圖 18、擴散模型加噪去噪概念示意	31
圖 19、反向過程第 t 時間步示意圖	32
圖 20、最後時間步推論流程示意圖	33
圖 21、DDPM3D 架構圖	34
圖 22、U-NET3D 架構圖	34
圖 23、RELU 與 SiLU 函數示意圖	37
圖 24、樹狀擴散模型建構流程圖	38
圖 25、ONLINE 詳細流程結構示意圖	40
圖 26、最終人群分布模擬示意圖	41
圖 27、BASELINE 模型架構圖	42
圖 28、最終分群結果樹狀擴散模型示意圖	48

圖 29、全地圖 LIGHTGBM 訓練曲線圖	49
圖 30、全地圖 LIGHTGBM SHAP 摘要及特徵重要度圖	50
圖 31、全地圖最大 SPLIT GAIN 決策樹(節錄)	50
圖 32、樹狀擴散模型框架骨幹	51
圖 33、累計人數誤差	52
圖 34、人數誤差>100 之累計小時數	52
圖 35、累計標準差誤差	52
圖 36、標準差誤差>1 之累計小時數	52
圖 37、單一網格 LIGHTGBM 訓練曲線圖	53
圖 38、台北燈節敏感網格分布圖	55
圖 39、累計人數誤差 TOP50 (深紅色網格)	56
圖 40、標準差誤差>1 之累計小時數 TOP20(深紅色網格)	56
圖 41、最終分群結果樹狀擴散模型示意圖	56
圖 42、LEAF MODEL 1 實驗模擬結果(LEAF1 - BASELINE)	57
圖 43、LEAF MODEL 1 實驗模擬結果(LEAF1 - BRANCH)	58
圖 44、LEAF MODEL 2 實驗模擬結果(LEAF2 - BASELINE)	59
圖 45、LEAF MODEL 2 實驗模擬結果(LEAF2 - BRANCH)	60
圖 46、LEAF MODEL 3 實驗模擬結果(LEAF3 - BASELINE)	61
圖 47、LEAF MODEL 3 實驗模擬結果(LEAF3 - BRANCH)	62
圖 48、LEAF MODEL 4 實驗模擬結果(LEAF4 - BASELINE)	63
圖 49、LEAF MODEL 4 實驗模擬結果(LEAF4 - BRANCH)	64
圖 50、LEAF MODEL 5 實驗模擬結果(LEAF5 - BASELINE)	65
圖 51、LEAF MODEL 5 實驗模擬結果(LEAF5 - BRANCH)	66
圖 52、LEAF MODEL 6 實驗模擬結果(LEAF6 - BASELINE)	67
圖 53、LEAF MODEL 6 實驗模擬結果(LEAF6 - BRANCH)	68
圖 54、LEAF MODEL 7 實驗模擬結果(LEAF7 - BASELINE)	70
圖 55、LEAF MODEL 7 實驗模擬結果(LEAF7 - BRANCH MODEL)	71
圖 56、LEAF MODEL 8 實驗模擬結果(LEAF8 - BASELINE)	72
圖 57、LEAF MODEL 8 實驗模擬結果(LEAF8 - BRANCH MODEL)	73

第一章 緒論

1.1 研究背景與動機

在高度都市化的今日，人口大量集中於都會區，高密度的人群活動已成為現代城市治理的關鍵挑戰，使得城市中的人群動態分析成為一項重要的研究議題[73]。而台灣又因有著地狹人稠的人群分布特性[70]，並因其特殊地理位置而頻遭颱風、地震等天災侵襲[71]，因此尤為重視災防管理領域的人群兵棋推演。人群兵棋推演的核心目的，即是透過模擬災害發生時，城市在不同人群分布情境下的應變能力與策略，從而找出能將災害衝擊降至最低的方案。城市中的人群分布，其本質可被視為一種複雜的時空資料，舉例來說，一場兵棋推演可能會模擬強烈颱風在不同時間點登陸都會區的影響。若颱風於「平日上午」來襲，大量通勤人流將高度集中於交通要道、商業辦公大樓及各級學校；然而，若場景切換至「週末晚間」，人群則可能廣泛分布於住宅區、購物中心或娛樂場所。這兩種截然不同的時空分布情境，將直接導向完全相異的疏散策略、資源部署與救援路徑規劃。因此，能否精準地預測或生成在特定情境下(如時間、天氣、事件)的高保真度人群分布圖，便成為提升兵棋推演真實性與有效性的核心關鍵，這也正是本研究試圖解決的問題。從上述兵棋推演的案例可以發現，除了基礎的時空維度，人群分布同時也深受氣象、特殊事件等外部因素的顯著影響 [1][11][60]。例如，本研究的模型可以生成兩種截然不同的未來情境。如圖 1 所示，在未來某個冬日的涼爽陰天下午，人群可能高度集中於特定熱點，例如台北車站單一網格的模擬人數可超過兩萬人。然而，如圖 2 所示，若情境切換為未來某個夏日的濕熱雨天早晨，戶外活動大幅減少，模型則可能預測出整座城市的人群分布變得極為平均且稀疏，各網格人數均在數千人以下。這兩張模擬圖的顯著差異，充分說明了不同的時空與外部條件組合，將產生迥異的人群分布樣態。因此，一個能夠有效模擬未來在

各種情境下之高保真度人群分布的模型，對於提升災害兵棋推演的成效至關重要。




圖 1、2028/2/27 15:00 人群分布

圖 2、2027/8/9 08:00 人群分布

為應對大規模人流預測的挑戰，過往研究已發展出多樣化的方法，但若以本研究生成未來任意時刻情境的目標來檢視，則各有其應用侷限。首先，傳統的人群數值預測旨在建立時間序列模型[31][43][52]，以輸出未來短時間內(如數小時後)的人流數值，此方法廣泛應用於道路交通流量或計程車需求預測等領域[65][62][57]。然而，這類預測模型的根本限制在於其準確性會隨著預測時間的拉長而顯著衰退，使其難以適用於本研究欲模擬的、距離當下較長遠的特定未來情境。其次，人群移動軌跡預測[20][38][55]主要利用個人的 GPS 等軌跡資料，來學習並預測個體或群體的移動路徑與模式。雖然此方法能提供精細的移動路徑資訊，但本研究的核心目標是獲取在特定時間點下，各個地理網格內的總人數，而非個體的移動過程，故兩者目標並不一致。再者，人群數量統計[4][8][59]是透過固定的感測器，如城市中的攝影機，來即時監控並計數特定地點(如一條道路或景點入口)的當下人數。此方法的本質是觀測而非生成，因此它雖然能提供特定地點的即時數據，卻無法被應用於模擬一個尚未發生的、基於特定條件的假想情境，這與本研究的生成目標有所抵觸。即便有研究提出以 k-Nearest Neighbour

(kNN)[17]等方法尋找歷史相似案例進行模擬[50]，亦常面臨預測數值不連貫的問題。為了解決傳統預測模型的局限，許多研究已轉向探索生成式模型的潛力。近年來，為了解決傳統模型無法生成特定情境樣本的問題，有學者將條件式生成對抗網路(Conditional Generative Adversarial Network, cGAN)[24]引入此領域[69]並加以改良[68]。cGAN 在傳統 GAN 的架構基礎上，為生成器(Generator)與判別器(Discriminator)同時引入了條件變數(Condition)[37]，例如特定的時間或天氣特徵。這使得生成器學會產生符合該條件的數據，而判別器不僅要判斷數據的真偽，還要判斷數據是否與給定條件相符。然而，儘管 cGAN 賦予了模型生成可控情境的能力，它並未完全解決 GAN 固有的核心瓶頸。其訓練過程依然依賴於生成器與判別器之間的對抗，這同樣可能導致訓練過程難以收斂。更嚴重的是，模式崩潰(Mode Collapse)[5]的問題在 cGAN 中依然存在：在某些條件下，生成器可能只學會了產生少數幾種能騙過判別器的安全樣本，導致生成結果缺乏多樣性，無法真實反映在該條件下應有的完整數據分佈樣貌。

有鑑於 cGAN 的潛在瓶頸，本研究採用擴散模型(Diffusion Model)作為核心的生成技術[28]，以應對生成高品質、多樣化且可控人流分布的挑戰。擴散模型是一種模擬擴散現象的生成模型。其核心機制包含兩個階段：首先是一個固定的前向過程(Forward Process)，在此過程中，模型會逐步、可控地對真實資料(如人流圖)疊加高斯雜訊，直到原始資料完全變成一張純粹的隨機雜訊圖。接著，模型的核心任務是學習一個反向去噪過程(Reverse Process)，即訓練一個神經網路(U-Net 架構)，使其能夠從一張純雜訊圖開始，逐步地預測並移除每一步的雜訊，最終還原出一張清晰、真實的數據樣本。此方法的優點在於，它以一個相對簡單且穩定的降噪目標，取代 cGAN 中複雜且不穩定的對抗式訓練。由於模型在任何時刻都只專注於預測雜訊這個單一且明確的任務，而非與另一個模型進行零和博弈，因此從根本上避免了模式崩潰的問題，並大幅提升了訓練過程的穩定性，為生成

高品質且可控的數據提供了一條更為可靠的新途徑。




圖 3、2018 九合一大選與週六平均人群差異百分比

擴散模型在生成高品質模擬上展現了強大的潛力，若要將其應用於模擬整座城市的人群，則必須應對異質性所帶來的挑戰，一個在單一通用模型與多重獨立模型之間的兩難困境。若採用以單一模型預測全城市的策略，雖然架構單純，但會面臨學習上的挑戰，城市中的人流變化極其多元，其驅動因子亦不盡相同，例如平日的通勤人流、週末的休閒人潮、以及特定節慶或活動等等。如圖 3，2018 九合一大選與平常週六人群分布截然不同。而以台北市為例(圖 4)，交通樞紐台北車站、西門町商圈以及萬華夜市，其人流模式便受不同因子驅動。試圖用一個單一模型去學習所有這些複雜且互斥的模式，不僅效率低落，更可能使模型為了兼顧所有情境而產生平均化結果，無法捕捉區域的獨特細節。而另一方面，若採用各網格各自建模的策略，為城市中的每一個網格都獨立建立一個專屬模型，則會面臨其他問題。首先，此方法雖然能適應各區域的獨特性，卻會衍生出極高的計算成本，在模型訓練與維護上不切實際。其次，由於模型之間各自獨立，可能

忽略網格與網格之間的空間關聯性，無法模擬人流的跨區移動等重要的空間現象。




圖 4、台北車站周邊異質性示意圖

本研究的核心概念是提出樹狀擴散模型(Diffusion Tree)框架，如圖 5 所示，我們首先結合影響因子分群、樹狀擴散模型架構、以及遷移學習等技術在人群模擬的應用，以解決過往研究遇到的挑戰。建立影響因子分群機制：為解決大範圍區域內影響因子異質性的問題，具體研究目的條列如下：




圖 5、樹狀擴散模型(Diffusion Tree)架構示意圖

1. 本研究提出影響因子分群的概念。利用 LightGBM 模型的特性快速計算出對每個網格人群最重要的影響特徵，再以帶來最大分裂增益(split gain)的特徵為依據，將所有網格自動分群，確保群內的網格具有相似的人群分布模式
2. 引入擴散模型作為生成核心：為克服 GAN 不穩定與模式崩潰的問題，本研究將採用擴散模型作為生成高品質人流分布圖的核心技術。利用其穩定的訓練過程與強大的分佈學習能力，生成比傳統方法更真實、更多樣化的模擬結果。
3. 提出樹狀擴散模型架構：為解決單一模型與多模型之間的成本與精度權衡問題，本研究提出一個創新的「樹狀擴散模型」架構。此架構包含以下步驟：
 - (1)預訓練：針對整個城市的人流分布訓練一個通用的根模型(Root Diffusion Model)，作為模型骨幹。
 - (2)遷移學習：基於第一點的分群結果，將根模型使用遷移學習的方式，建立各個分支模型(Branch Diffusion Model)與葉模型(Leaf Diffusion Model)，使其能快速適應不同群組的資料特性，讓模型不需要從頭學習。
 - (3)輕量化：在確保精度的前提下，對分支與葉模型進行簡化(如降低模型深度、減少輸入通道)，以大幅提升整體模型訓練與推論的效能。
 - (4)異質性情境生成：得益於階層式架構，系統能根據輸入的複雜情境，自動為地圖上的每個區域匹配最適合的 Leaf Model 進行推論，最終將各個專家模型的生成結果整合成一張能反映局部細微差異的全域分布圖。
 - (5)特殊事件的有效訓練：透過預訓練與遷移學習，Leaf Model 繼承了通用的圖像生成知識。此舉大幅降低了對數據量的要求，使得那些樣本數較少、難以獨立建模的特定情境能夠被成功地訓練與模擬，也提升了訓練資料的

利用效率。

論文之其餘章節安排如下：

第二章為文獻回顧，將探討人群分布與生成式模型相關領域之過往研究，並分析其優點與侷限。第三章為資料集介紹，將詳述本研究使用之人流資料、天氣、日曆與特殊事件等輔助資料的來源、特性與整合方法。第四章為本研究核心之研究方法，將闡述從資料前處理(包含 Z-score 標準化與匈牙利演算法)、利用 LightGBM 進行特徵分群，到擴散模型的基本原理，並詳細介紹本研究提出的「樹狀擴散模型」之階層式架構與訓練流程。第五章為實驗模擬與結果分析，將呈現各階段模型的訓練過程與成效，並對本研究提出之樹狀擴散模型的生成結果，進行多面向的量化、質化評估與比較。第六章為結論與未來展望，將總結本研究之主要貢獻，並提出未來可行的研究方向。

1.2 研究範圍與限制

本研究的地理範圍設定為全台北市。研究將利用涵蓋此範圍的真實資料集進行模型的訓練、驗證與分析，旨在建立一個能反映整個都會區人群分布的模擬系統。本研究在執行過程中，存在以下限制：

1. 無法考慮未發生過的事件因子：本模型使用歷史數據進行學習，因此對於資料庫中從未出現過的全新事件類型(例如一種新型態的公眾活動)，或是新的影響因子(例如新的大型公共建設)，模型可能無法準確預測其造成的人流影響。
2. 常用評估指標的適用性問題：在圖像生成領域，常用於評估擴散模型的指標如 Inception Score (IS)，其設計原理是基於對真實世界物件的辨識。此類指標並不適合直接應用於評估抽象的人流熱力圖的品質。

3. 樹狀架構的深度限制：本研究所提出的樹狀擴散模型，其可劃分的深度與廣度，直接受限於歷史資料的筆數與分佈情況。若某些特定條件組合的數據過於稀疏，將難以對其建立獨立的分支或葉模型。



國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

第二章 文獻回顧

本章節旨在回顧與本研究相關的文獻，探討重點將包含以下幾個領域：首先是人群分布的影響因素；其次是時空間資料的預測與分群演算法；最後則是 LightGBM 與擴散模型等相關機器學習模型的理論與應用。

2.1 人群分布影響因素

人群在特定時間於空間中的聚集狀態，即為人群分布。這種分布是動態的，它由無數個體的移動行為(如通勤)匯集而成，並隨時在改變[73][11]。然而，人群分布並非恆定不變，而是受到多種外部因素的複雜影響，包含時間週期、空間維度、天氣因素以及特殊事件影響等等。

在時間週期上，「平假日」與「晝夜」的差異是影響人群分布的關鍵[2]。例如，Arnberger 等人[3] 的研究便觀察到，城市與森林遊憩區的人群數量在平假日有明顯不同；Ali 等人[1]與 Cheng 等人[11]在交通流量預測中，也驗證了不同時間點會形成特定的聚集模式。

空間維度上，不同的地理環境亦呈現相異的人群分布特徵[1][2][60]。Deng 等人[18]透過智慧卡資料發現，不僅各城市間存在獨特的分布模式，城市內部的住宅區、商業區與休閒區也各自擁有不同的分布規律，而這些規律同樣受到時間因素的調控。

除了常規的時間週期與空間維度，天氣條件這類外部因素也是驅動人群分布變化的關鍵變因[60]。具體而言，天氣直接影響人們的出行意願與活動場域的選擇：例如，暴雨、酷暑或颱風等惡劣天氣會顯著抑制戶外的非必要移動，可能導致公園、商圈等開放空間的人潮銳減，同時將人流引導、集中至室內的購物中心或交通樞紐。

最後，特殊事件的影響也不容忽視。Gong 等人[23]利用社群媒體資料指出，特殊活動不僅會引發舉辦地的人群聚集，其影響更會擴散至周邊區域，從而改變局部的人群分布狀態。

2.2 時空資料預測演算法

時空資料預測是利用歷史數據中蘊含的時間與空間關聯性，來推斷未來狀態的關鍵技術，在交通規劃、環境監測、氣象預報及公共安全等領域均有重要應用。縱觀其發展，預測演算法已從早期的統計與機器學習模型，逐步演進為現今以深度學習為主導的複雜框架[58]。為此，本節將依序探討其發展的兩個主要階段：首先回顧奠定早期探索與基礎模型；接著再探討深度學習如何透過時空特徵融合學習人群分布的影響因素。

早期基礎模型：在深度學習普及之前，研究者們已開始嘗試使用不同方法解決時空預測問題。例如，Park & Rilett [39] 便開創性地應用多層前饋神經網路來預測高速公路的交通時間，為後續研究奠定了基礎。然而，要有效捕捉數據中的時間序列依賴性，其核心突破來自於 Hochreiter & Schmidhuber [29] 提出的長短期記憶模型 (Long Short-Term Memory, LSTM)。LSTM 透過其創新的「門控」單元結構，有效解決了傳統循環神經網路在處理長序列時的梯度消失問題，使其成為後續所有處理時序依賴性任務的基石。除了神經網路，傳統機器學習路徑亦有所發展，如 Feng 等人[21]利用多核支持向量機 (Support Vector Machine) 結合時空相關性，在短期交通流預測上取得了良好效果，展現了不同技術路徑的可能性。

深度學習與時空特徵：隨著大數據時代的來臨，研究的焦點轉向如何更有效地融合多源、異質的數據。Zheng 等人[63]的 U-Air 研究便是一個指標性的例子，該研究整合氣象、交通、地理等多維度資料來進行精細化的空氣品質預

測。同樣在環境監測領域，Chang 等人[10]也運用機器學習技術探索了台灣北部地區 PM2.5 的時空特徵。這些研究突顯融合複雜時空交互資訊的重要性。除了預測任務，學界也利用時空數據進行深度分析，例如從不可靠的 GPS 數據中辨識興趣點[6]，或是分析道路上的煞車排碳行為[14]。為了在模型架構上更原生、更有效地同時處理時間與空間特徵，一個關鍵的里程碑是 Shi 等人 [46] 提出的卷積長短期記憶網路 (Convolutional LSTM, ConvLSTM)。ConvLSTM 將 LSTM 中的矩陣乘法替換為卷積運算，使得模型在傳遞時間資訊的同時，能夠直接捕捉數據中的空間拓撲結構。此架構成為處理網格狀時空資料的典範。基於此思想，更多複雜的深度時空網路被陸續提出。其中，由 Zhang 等人 [60][60] 開發的深度時空殘差網路 (ST-ResNet) 影響深遠。該模型巧妙地利用殘差網路結構，捕捉了城市人群流量中不同時間尺度(如近期、每日週期、每週趨勢)的依賴關係，並整合外部因素，顯著提升了全域預測的準確度。此後，研究者不斷探索更精細的架構，如 Lin 等人 [36] 提出的 DeepSTN+ 引入了語境感知機制，以應對大都會區高複雜度的流量預測；Chen 等人[15] 則利用多個局部的 3D-CNNs 進行區域性預測；而 He 等人[27] 更提出了結合 Densenet、ConvLSTM 與 ResNet 的複雜混合模型，將時空預測框架推向新的高度。近年來，深度學習時空預測框架的應用領域不斷擴展，並進入了更深入的性能評估階段。例如，Amato 等人[2] 提出了一個新穎的深度學習框架，用於處理氣候與環境監測中常見的非平穩、多變時空現象。而 Kartal & Erturk[33] 的研究則深入比較了 LSTM、CNN 及混合模型在海表溫度預測上的能力，系統性地評估了不同深度學習架構在處理大規模自然現象時，整合時空資訊的協同作用。這些研究不僅展現了時空預測技術的成熟，也為特定領域的應用提供了重要的實踐依據。

2.3 時空資料分群演算法

時空資料分群旨在從包含時間與空間維度的數據中，發掘具有相似特徵的群體。根據其處理的維度，過往研究大致可分為三類：僅考量時間特性的方法、僅考量空間特性的方法，以及能同時整合時空雙重特性的方法。

以時間特徵為主的分群方法：在僅考量時間維度的分群方法中，常見作法是採用一種管線式 (pipeline) 的流程：首先從時間序列中提取關鍵特徵，再將這些特徵投入傳統的分群模型中進行分析。特徵提取的主流方法之一是採用相似度量測。例如，部分研究運用動態時間扭曲 (DTW) 來計算序列間的相似度，並藉此分析客戶退貨行為[48] 或遊戲玩家的相似性[51]。Wang 等人[53] 更是在 DTW 的基礎上結合歐幾里得距離 (ED)，提出了效果更佳的 ED-DTW。另一種方法則是透過降維技術，如 Jiang 等人[32] 使用主成分分析 (PCA) 提取交通流量數據的主要變化特徵。在取得這些特徵或相似度矩陣後，研究者們便應用如 K-means[32][48][53] 或階層式分群法 (AHC)[51][56]等經典演算法來完成最終的群體劃分。

以空間特徵為主的分群方法：若僅考量空間維度，分群演算法大致可依其核心原理分為三類。以距離為基礎 (Distance-based)，此類方法以 K-means 為代表，透過計算樣本點間的距離來劃分群體，常被用於找出地理上的群體中心點，例如對城市居民進行分群[61]。以密度為基礎 (Density-based)，以 DBSCAN 為核心的密度分群法，擅長發掘任意形狀的群集並能有效過濾雜訊點。因此，它廣泛適用於不規則邊界的區域劃分，如軍事偵察範圍規劃[26]或城市供水點的優化佈局[30]。部分研究也對 K-means 與 DBSCAN 在特定場景 (如貧民窟辨識)下的優劣進行了比較[49]。模糊分群 (Fuzzy Clustering)，此方法引入了「隸屬度」的概念，允許一個樣本點可以屬於多個群體，提供了更具彈

性的劃分方式。這種特性使其在需要處理不確定性與漸變邊界的問題上特別有效，例如城市土地分級[25]或災害風險評估[42]。

整合時空雙重特性的分群方法：然而，上述方法皆是將時空問題降維至單一維度進行處理。為實現真正意義上的時空分群，需要能同時處理雙重維度的演算法。在這方面，由 Birant 等人[7] 於 2007 年提出的 ST-DBSCAN 是一個標誌性的演算法。ST-DBSCAN 的核心思想是將傳統 DBSCAN 的概念從一維空間擴展至多維。它在原本衡量空間鄰近性的距離參數之外，新增了第二個參數來衡量非空間屬性(如時間)的鄰近性。透過同時設定空間與時間的距離閾值，ST-DBSCAN 能夠有效地在時空數據中找出「在空間上相近」且「在時間上也相近」的群體。這個創新的框架使其在真實世界的應用中獲得成功。例如，Chimwayi 等人[16] 應用 ST-DBSCAN 對長達十年的西尼羅河病毒數據進行分群，成功探索了疾病的傳播模式與趨勢；Chen 等人[13] 則利用它對購物資料進行分析，從而發現了不同地區客戶的時空購買模式。

2.4 LightGBM

梯度提升決策樹 (Gradient Boosting Decision Tree, GBDT) 是一種強大且廣泛應用的集成學習演算法[22][44]，但傳統的 GBDT 實作在面對大規模、高維度的數據集時，常因需要重複掃描全體數據來尋找最佳分割點，而面臨嚴重的性能瓶頸。為了解決此問題，Ke 等人 [34] 提出了 LightGBM (Light Gradient Boosting Machine) 框架，其核心目標在於維持高準確性的同時，顯著提升模型的訓練速度並降低記憶體消耗。LightGBM 的高效能主要歸功於其採用的兩項創新技術：梯度單邊採樣 (Gradient-based One-Side Sampling, GOSS) 與 互斥特徵捆綁 (Exclusive Feature Bundling, EFB) [34]。

梯度單邊採樣 (GOSS): 傳統 GBDT 演算法在每次迭代中，需要計算所有樣本的梯度。GOSS 的核心思想是，梯度較大的樣本點對模型的貢獻更大，而梯度較小的樣本點則代表模型已能良好擬合。因此，GOSS 在訓練過程中保留所有梯度較大的樣本，並對梯度較小的樣本進行隨機採樣。透過這種方式，GOSS 大幅減少了需要計算的數據量，從而顯著提升了訓練速度，且對模型精度的影響極小。

互斥特徵捆綁 (EFB): 在高維度的稀疏數據中，許多特徵是互斥的(即它們很少同時為非零值)。EFB 技術能識別這些互斥特徵，並將它們「捆綁」成單一的新特徵，以此有效減少特徵的維度。特徵數量的降低，不僅直接減少了建立決策樹時的計算複雜度，更重要的是大幅降低了模型的記憶體佔用，使其能處理更大規模的數據集。

除了上述兩項核心技術，LightGBM 還採用了基於直方圖 (Histogram-based) 的演算法來尋找最佳分割點，並以帶有深度限制的逐葉生長 (Leaf-wise) 策略來建構決策樹。相較於傳統的逐層生長 (Level-wise) 策略，逐葉生長能更有效率地找到降低損失最大的分割點，從而用更少的迭代次數達到收斂，進一步提升了訓練效率。

LightGBM 在速度與記憶體上的卓越表現，使其在各種機器學習任務中備受青睞。例如，Sheridan 等人 [45] 在一項全面的比較性研究中發現，LightGBM 在定量構效關係 (QSAR) 任務上的預測準確度，足以媲美甚至超越隨機森林等當時的標準方法，同時訓練速度快上數百倍，證實了其在兼具準確性與高效性的強大潛力。

2.5 擴散模型

擴散模型是近年在生成式人工智慧領域取得突破性進展的一類深度學習模型。其核心概念源於非平衡熱力學，由 Ho 等人 [28] 在其開創性論文中提出的去噪擴散概率模型 (Denoising Diffusion Probabilistic Models, DDPM) 所奠定。DDPM 的運作包含兩個過程：首先，在「前向過程」中，模型會逐步對真實資料(如圖像)加入高斯噪聲，直至其變為純粹的隨機雜訊；接著，在「反向過程」中，訓練一個神經網路來學習如何逆轉這個加噪的過程，即從純粹的雜訊逐步去噪，最終還原出一個符合原始資料分佈的、全新的生成樣本。

此一框架的潛力很快便獲得驗證。Dhariwal & Nichol [19] 的研究證明，經過架構優化與引入分類器引導 (Classifier Guidance) 技術後，擴散模型在圖像合成的品質上，能夠全面性地媲美甚至超越當時最強的生成對抗網路 (GANs)，確立了其在生成領域的領導地位。憑藉其強大的生成能力，擴散模型的應用迅速從圖像合成擴展至自然語言處理、序列生成乃至於本研究關注的複雜時空系統分析 [66]。在人群分析領域，擴散模型主要展現於兩大應用方向：人群計數與密度估計，以及人群軌跡預測與模擬。

於人群計數與密度估計之應用：在人群計數與密度估計任務中，擴散模型提供了應對數據稀少與領域差異等挑戰的新穎思路。初期的應用之一是將其作為資料擴增的工具，例如 Wang 等人 [54] 利用擴散模型學習真實人群圖像的密度分佈，並以此生成大量帶有準確標註的合成圖像，有效緩解了下游計數模型的過擬合問題。隨後，研究者們開始嘗試將擴散模型用於直接預測密度圖。其中，Ranasinghe 等人 [40] 提出的 CrowdDiff 模型是此方向的開創性工作。該模型利用條件擴散過程，不僅能從輸入圖像中生成高保真度的密度圖，還具備生成多重假設 (Multi-hypothesis) 預測的能力，此特性在處理具有高度不確定

性的擁擠場景時，展現出超越傳統方法的穩定性與準確性。為了解決更具挑戰性的跨場景人群計數問題，Zhu 等人 [64] 則提出了 FGFD 模型，透過在片段級別對齊不同領域的特徵分佈，顯著提升了模型在未知場景中的泛化能力。

於人群軌跡預測與模擬之應用：在更動態的人群軌跡預測與模擬領域，擴散模型因其能捕捉多模態(Multi-modal)特性的能力而備受關注。人群的移動行為本質上充滿不確定性，單一個體的未來路徑可能存在多種合理選項。擴散模型恰能對此機率分佈進行建模，從而生成多樣且真實的預測結果。

早期的探索如 Cardia 等人 [68] 已開始將群體擴散的關聯性納入人群流動預測框架。近期研究則更為深入，例如 Sun 等人 [47] 提出的 GDTS 模型，透過目標引導與高效的樹型抽樣算法，專門應對大規模場域中的多模態人行軌跡預測。Lin 等人 [35] 的 GFTD 框架則透過擬合完整的過去與未來軌跡，強化了模型對雜訊與不完整數據的穩健性，在需要高可靠性預測的人機互動場景中展現潛力。

除了預測，擴散模型亦被用於人群模擬。Chen 等人 [12] 提出的 SPDiff，創新地將經典的社會力模型(Social Force Model)物理規則與擴散模型結合，使其生成的群體運動既符合物理規律，又具有真實世界的異質性。而在動畫與虛擬實境領域，Rempe 等人 [41] 則發展了可控式的引導擴散模型，允許使用者對生成的人群路徑、速度甚至社交關係進行約束，大幅提升了人群模擬的易用性與真實感。

第三章 資料集

本研究使用之資料集共包含兩種類型，第一種是作為模型預測目標的目標資料集，其類型為網格形式的人群分布資料；第二種是輔助資料集，包含天氣資料、日曆資料以及特殊事件資料，用以提供模型關於時空背景的上下文資訊。此二種資料集經整併後，將共同作為後續 LightGBM 特徵分析模型以及擴散模型的輸入資料。我們分成以下小節介紹這些資料集。

3.1 人群資料

表 1、人流資料範例

Timestamp	Lon1, Lat1	...	Lon1, Lat10
2018-01-01 00:00:00	121	...	88
2018-01-01 01:00:00	119	...	79
...	...	...	...
2019-12-31 23:00:00	123	...	96

本研究使用的人群分布資料源自電信公司提供之匿名人流資料。資料的時間範圍橫跨兩年，自 2018 年 1 月 1 日起至 2019 年 12 月 31 日止，時間解析度為每小時一筆，共計 17,520 個時間點。在空間維度上資料涵蓋的地理範圍為經度 121.46 至 121.665，緯度 24.965 至 25.21，將台北市以 500 公尺 x 500 公尺的正方格切割，每個網格代表一個區域的人群數量，共計 495 個網格。每一筆資料都記錄了在該小時內，各個網格中的人流量。因此，這份目標資料集的最終形式是一個維度為(17520, 495)的時間序列矩陣，每一列代表一個小時，每一行則對應一個地理網格的人流數值(表 1)，可被視為一系列連續的人流熱力圖，如圖 6 所示意。

剩下的詳細資訊因為本研究有跟資料提供單位簽署保密協定，所以無法提供。




圖 6、人群資料空間示意圖

3.2 輔助資料



圖 7、CODiS 查詢介面[67]

為了讓模型能學習到造成人流變化的潛在因素，本研究引入了三類輔助資料，分別為天氣資料、日曆資料與小巨蛋活動資料。天氣可能是影響人群戶外活動意願的因素。本研究的天氣資料取自「交通部中央氣象署觀測資料查詢系統 (CWB Observation Data Inquire System, CODiS)」，圖 7 為該網站的查詢介面。我

們蒐集了與研究期間相對應的共 17520 小時氣象資料，如表 2 所示，每小時的資料都包含 16 個欄位如：氣溫 (Temperature)、相對溼度 (RH)等。

表 2、氣象資料欄位

Field	Description	Unit
Temperature	氣溫	°C
Td dew point	露點溫度	°C
RH	相對溼度	%
WS	風速	m/s
WSGust	最大瞬間風速	m/s
WD	風向	Degree
WDGust	最大瞬間風向	Degree
Precp	降雨量	mm
PrecpHour	降雨時數	Hour
SunShine	日照時數	Hour
GlobRad	全天空日射量	MJ/m ²
Visb	能見度	Km
UVI	紫外線指數	Number
Cloud	總雲量	0~10
SeaPres	海平面氣壓	hPa
StnPres	測站氣壓	hPa

為使模型能捕捉時間上的週期性與趨勢性，本研究整理了一系列日曆相關特徵。這些特徵對於區分平日與假日、工作日與週末，以及一天內不同時段(如通勤高峰、夜間離峰)的人流模式至關重要。建構的特徵包含：是否為假日：布林值，包含國定假日與週末，星期幾：數值為 0 至 6，分別代表星期一至星期日，年: 2018 或 2019，月: 一至十二月，日: 1 至 31，小時：數值為 0 至 23。

除了常規的週期性規律，城市的人群分布也常受到非週期性、地點特定的大

型活動所影響。這些活動能在短時間內，於特定區域(如展演場館、節慶場地)吸引或疏散大量人潮，其引發的人群分布變化，遠超過常規模式所能解釋的範圍。在本研究中，我們將這類能引發局部人潮劇變的外部條件，我們將整合後的資料額外新增欄位，標註活動是否進行，這些活動是否發生的布林欄位統稱「事件因子」。

為了捕捉這些事件因子，本研究針對兩種不同尺度的活動進行了資料蒐集與處理。固定場館活動：以台北小巨蛋為例，我們透過網路爬蟲技術，蒐集其官方網站的年度活動日程表(如圖 8)。接著，我們將活動資訊整理為布林特徵，例如「該時段是否有活動」、「是否為演唱會」等，用以標示每個時間點的場館狀態。大規模都市節慶：針對範圍更廣的活動，本研究則以台北燈節與新北耶誕城為例。我們根據歷年官方新聞稿所公布的活動日期與時間，直接對相應時段的整合人群資料進行標註，以體現這些大型節慶對全市或跨區域人流的影響。



編號	標題	發布日期
1	2025/07/05《2025CTC世界盃國際標準舞公開賽》	114-07-05
2	2025/06/28《第36屆流行音樂金曲獎頒獎典禮》	114-06-28
3	2025/06/21《2025hito流行音樂獎頒獎典禮》	114-06-21
4	2025/06/13、06/14、06/15《伍佰 & China Blue Rock Star2 演唱會 台北站》	114-06-13
5	2025/06/07《彭佳慧2025演唱會》	114-06-07
6	2025/05/31、06/01《美國高空大馬戲團》	114-05-31
7	2025/05/19-05/24、05/27-05/29《2025臺北世界壯年運動會-柔道、運動舞蹈》	114-05-19

圖 8、小巨蛋官方網站[72]

3.3 資料整合與切割

在模型訓練前，上述所有資料源將以「小時」為共同的時間索引進行對齊與合併。最終，我們得到一個完整的結構化資料表，其維度為 (17520, 520)。每一列代表一個小時的完整狀態，共包含 25 個輔助特徵：包含 6 個日曆特徵、16 個天氣特徵、以及 3 個小巨蛋活動特徵。495 個目標特徵：代表 495 個網格在該小時的人流量。

為確保模型評估的客觀性與公平性，本研究採用時間上的序次切割，將資料集分為訓練集、驗證集與測試集，避免模型在訓練時看到未來的數據。切割方式如下：總共 17,520 筆的完整資料集進行隨機重排，並分成訓練集 (Training Set)：取前 70% 的數據，驗證集 (Validation Set)：接著取 15% 的數據，測試集 (Test Set)：取最後剩餘的 15% 的數據，確保三個子集資料分佈相似。

國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

第四章 研究方法

本研究提出一個結合決策樹、特徵工程與擴散模型的「樹狀擴散模型」框架，旨在高效率地生成大範圍且高保真度的人群分布。整體系統流程如圖 9 所示，其離線 (Offline) 訓練階段主要分成三個部分：第一部分為資料前處理，此階段旨在將原始的人群與輔助資料進行清洗、轉換，並透過匈牙利演算法將真實世界的地理座標映射至標準化的網格矩陣。第二部分為樹狀結構主幹模型的建立。此階段首先利用 LightGBM 建構一個「全地圖決策樹」，並以此為基礎，接續完成 Root Model 與 Branch Model 的階層式訓練，構成整個預測模型的上層結構。第三部分為葉節點模型的特化訓練。此階段為本研究的核心，旨在為不同的數據子集建立專屬模型。它綜合利用了來自 LightGBM 的「網格與事件特徵分群」，以及來自 Branch Model 的「誤差結果分群」，來將數據進行精細劃分，並為各個分群結果訓練出對應的 Leaf Models。

為了整個流程介紹的完整度與流暢性，本章節介紹時將不會完全依照圖 9 系統流程圖的順序。在 4.2 節中，我們將先詳細介紹 LightGBM 模型及其在本研究負責的四個主要分群任務。而第二部分的 Root Model 與 Branch Model，將會合併至 4.4 節的「樹狀擴散模型」中與第三部分的 Leaf Model 一併說明，以確保整體階層式架構的連貫性。

當離線模型訓練完成後，即可進入 Online 推論流程。使用者僅需提供欲查詢情境的特徵資料，系統即可依循樹狀結構，由 Root Model 開始，途經 Branch Model，最終由特定的 Leaf Model 生成該情境下最終的人群分布預測圖。本章節將依序詳細介紹各部分的實作方法。




圖 9、系統流程圖

4.1 資料前處理

資料前處理是模型訓練前的關鍵步驟，其目的在於將原始、異質的數據轉換為乾淨、標準化且適合機器學習模型使用的格式。本研究的前處理流程包含特徵工程、資料標準化，以及將真實地理座標映射至標準網格的匈牙利演算法。首先，我們進行了初步的特徵工程，包含：將風向欄位透過三角函數轉換為 $\sin$ 與 $\cos$ 值，以解決角度的週期性問題。根據爬蟲蒐集的資料，人工標註小巨蛋活動類型(如演藝活動、其他活動)的布林特徵。將部分欄位(如 holiday, weekday)轉換為模型易於處理的類別特徵。

我們針對數值型資料進行標準化。在人群與天氣資料中，時常會因為特殊事件或極端氣候而存在極端值，造成資料分布不均。若使用傳統的 Min-Max Scaling，其結果會被這些極端值嚴重影響，導致大部分數據被壓縮在一個極小的區間內，不利於模型學習。為此，本研究採用 Z-score Normalization 對人群與天氣等數值型特徵進行標準化，主要用於擴散模型的輸入。此方法具有以下特性：

(1)中心化與統計意義：轉換後的資料平均值為 0，標準差為 1。值為 0 的點代表了整批資料的平均中心，而任一資料點的 Z 分數則直接量化了該點偏離平均水平的標準差倍數。這種「偏離度」的資訊能為模型提供更豐富的特徵，有助於其區分「正常波動」與「異常事件」。相比之下，Min-Max 正規化後的 0.5 僅代表數值位於歷史最大與最小值的正中間，但這個中間點本身可能是一個不常出現的值，缺乏如平均值般的統計代表性(圖 10)。(2)對極端值穩健：相較於 Min-Max Scaling，Z-score 不會被極端值過度影響，能保留數據原始的分佈形狀，更具統計意義，有助於後續的資料觀察與模型學習。(3)對新資料的適應性：未來若有新資料加入，其標準化過程不受限於原始資料集的最小值與最大值，擴充性更佳。




圖 10、Z-score 與 Min-Max 比較

本研究的原始人群資料來自 495 個實際經緯度座標，其地理分佈並不規則。為了將這些不規則的點位資料轉換為一個標準的 20x20 網格矩陣以利於後續卷積神經網路的運算，本研究採用了匈牙利演算法。匈牙利演算法是一種解決「指派問題」的最佳化演算法，其目標在於找出兩個集合元素之間成本最低的一對一匹配方式。在本研究中，即是尋找 400 個真實座標點與 400 個標準網格點之間，總移動距離最小的最佳映射關係。詳細執行步驟如下：

1. 前置作業：定義來源點與目標點。建立目標網格：首先在記憶體中建立一個

虛擬的 20x20 網格矩陣，作為最終分配的目標。選取來源座標：解析原始資料集中所有的經緯度欄位，計算出所有點位的地理中心。接著，挑選出距離地理中心最近的 400 個座標點作為等待被映射的來源點，挑選結果如圖 11 所示。




圖 11、地理中心與篩選後座標點

2. 演算法執行：尋找最佳映射。

- (1) 建立成本矩陣：建立一個 400x400 的成本矩陣，其中每一個元素 $C(i,j)$ 的值，代表第 i 個真實座標點到第 j 個目標網格中心的直線歐幾里得距離。
- (2) 執行演算法：將此成本矩陣輸入匈牙利演算法。演算法透過迭代運算，找出一個能讓成本總和(即總移動距離)最小的一對一匹配組合。
- (3) 完成映射：演算法的輸出即為每個真實座標點應該被放置到的唯一網格位置。最終，我們根據此映射關係，將 400 個真實經緯度座標的數據，一一對應並重排至標準的 20x20 矩陣中，完成空間資料的標準化。映射後的矩陣如圖 12。




圖 12、20x20 人群矩陣示意圖

4.2 LighGBM

為了有效處理網格的異質性，並為後續的樹狀擴散模型提供一個結構化的分群依據，本研究引入了 LightGBM (Light Gradient Boosting Machine) 模型。我們並非使用 LightGBM 進行最終的人流預測，而是藉助其高效率的訓練過程與強大的特徵重要性分析能力，從全域和區域兩個視角對數據進行探索與分群。本節將先介紹 LightGBM 的核心技術，再簡述其在本研究中的四項主要任務：建立全地圖決策樹、網格特徵分群、事件特徵分群以及誤差情形分群。

LightGBM 是一個由微軟開發的、基於梯度提升決策樹 (Gradient Boosting Decision Tree, GBDT) 演算法的高效能開源框架。相較於傳統的 GBDT，LightGBM 透過以下幾項關鍵技術，在維持高準確率的同時大幅提升了訓練速度與記憶體使用效率：

1. 梯度單邊採樣 (Gradient-based One-Side Sampling, GOSS)：傳統 GBDT 需要遍歷所有數據來計算資訊增益，而 GOSS 改變了此策略。它保留了所有梯度較大(即誤差較大，訓練不足)的樣本，並從梯度較小的樣本中進行隨機採樣。這種方法在不嚴重影響精度的前提下，顯著減少了計算量。
2. 互斥特徵捆綁 (Exclusive Feature Bundling, EFB)：在高維稀疏數據中，許多

特徵是互斥的(即它們很少同時為非零值)。EFB 演算法能智慧地將這些互斥特徵捆綁成單一特徵，從而在不損失資訊的情況下有效降低特徵維度。

3. 葉節點導向的生長策略(Leaf-wise Growth)：傳統決策樹多採用層級導向(Level-wise)的生長策略，如圖 13 所示，對同一層的所有葉節點進行分裂。而 LightGBM 採用葉節點導向策略(圖 14)，每一次都從當前所有葉節點中，選擇分裂後帶來最大損失降低(max delta loss)的那個節點進行分裂。這種方法更有效率，能在相同的分裂次數下達到更低的誤差。




圖 13、Level-wise 示意圖




圖 14、Leaf-wise 示意圖

全地圖決策樹：LightGBM 的第一項任務，是從宏觀視角找出影響整座城市人流分布的最關鍵決策因子。此過程旨在為樹狀擴散模型的頂層結構(Root Mode 與 Branch Model)提供一個客觀的劃分依據。其執行步驟如下：

1. 使用涵蓋所有 400 個網格的完整資料集，訓練一個共享的 LightGBM 模型。
2. 在模型訓練完成後，從其生成的多個決策樹中，保存其中分裂增益(split gain)最大的一棵決策樹，如圖 15 所示。




圖 15、全地圖特徵決策樹(局部)

- 此決策樹中具有最大分裂增益的路徑，代表了能對整體數據帶來最大區分度的特徵與閾值。這個決策路徑將被用於後續樹狀擴散模型的建構，根結點作為 Root Model 的輸入，路徑中的第二第三節點將作為 Branch Model 的基礎。

網絡特徵分群：找出全域性的關鍵因子後，第二項任務是深入到微觀層面，分析每一個獨立網絡各自最重要的影響特徵，並據此進行分群：

- 首先，為避免與上一步的結果重疊，會先排除已找出的全域性關鍵特徵。
- 接著，針對 400 個網絡中的每一個，都獨立訓練一個專屬的 LightGBM 模型。
- 對於每個網絡，找出其對應模型中具有最高分裂增益的特徵。這個特徵可被視為該網絡人流模式的主要驅動因子。
- 最後，依照每個網絡的主要驅動因子進行分群。例如，所有以氣溫為最重要

特徵的網格被歸為一類，以相對溼度為最重要特徵的則歸為另一類。在初步分群後，會再將同特徵且閾值相近的群組進行整併，以確保群組的穩定性。此分群結果如圖 16 所示，將作為建置第三階段一部分 Leaf Models 的依據。



圖 16、網格特徵分群結果示意圖

事件特徵分群：第三項任務是專門為了捕捉非週期性的事件影響因子而設計。此任務旨在找出對特定事件(演唱會、燈會、耶誕城)反應特別敏感的網格。

1. 首先，將模型的輸入特徵限制為類別型特徵，如：特殊活動是否發生、holiday、weekday。
2. 為每一個網格獨立訓練一個 LightGBM 模型。
3. 將那些以事件特徵為最重要影響因子的網格，獨立劃分出來自成一個或多個群組，結果如圖 17 為對新北耶誕城敏感地點之分群。
4. 此分群結果同樣會用於建置第三階段的 Leaf Models，使其能專門學習並模擬特定事件發生時的人流變化模式。




圖 17、事件特徵分群結果示意圖

評估分析與誤差情形分群: 除了前述兩種分群外，本研究引入了一種基於模型性能反饋的分群機制。此步驟旨在找出 Branch Model 表現不佳的特定網格群體，並為其建立專門的修正模型。其流程如下：

1. 模擬與評估：首先使用訓練好的 Branch Model 模擬出整個資料集的人群分布，並與真實資料進行比較。
2. 計算誤差指標：針對每一個網格，計算四種不同面向的累計誤差指標，包含：累計正規化誤差((模擬值 - 真實值) / 標準差)、標準差誤差時數(正規化誤差絕對值大於 1 的總時數)、累計原始誤差(模擬值 - 真實值)、原始誤差超標時數(原始誤差絕對值大於特定閾值的總時數)。
3. 誤差分群：根據上述四種誤差的計算結果，將所有網格分為四類：正向誤差 Top k、正向誤差其餘、負向誤差 Top k、負向誤差其餘。
4. 尋找誤差因子：將分群結果輸入 LightGBM 進行分析，以找出造成各類誤差的最主要影響因子。

此分群結果最終將用於一部分 Leaf Models 的建立，使其能專門修正 Branch Model 在特定情況下的預測偏差。

4.3 Diffusion Model

本研究採用擴散模型(Diffusion Model)作為生成高品質、多樣化且可控人流分布的核心技術。本節將介紹其基本概念、訓練與推論流程，以及本研究所採用的具體模型架構。擴散模型的核心概念是學習如何逆轉一個將真實資料逐漸變成純粹雜訊的過程，概念如圖 18 所示。這個機制主要由兩個階段組成：

1. 前向過程 (Forward Process)：此為一個固定的、無需學習的過程。它會在一張真實的人群分布圖 x_0 上，透過數百至上千個步驟，逐步地、微量地疊加高斯雜訊，直到原始圖像最終變成一張完全無法辨識的隨機雜訊圖 x_T
2. 反向過程 (Reverse Process)：此為模型學習的核心。我們的目標是訓練一個深度學習模型，使其能夠執行前向過程的逆向操作。模型需要學習如何從一張純雜訊圖 x_T 開始，一步步地預測並去除其中包含的雜訊，最終還原出一張清晰且真實的人群分布圖 x_0 。此方法的巧妙之處在於，模型本身並不需要學習如何從無到有直接畫出一張複雜的人流圖，而只需要專注於判斷並預測雜訊這個相對簡單的任務，從而大幅降低了學習的難度。




圖 18、擴散模型加噪去噪概念示意

訓練流程：擴散模型的訓練流程，旨在教會一個雜訊預測器 (Noise Predictor) 如何在任意噪音級別下，精準地預測出被疊加的雜訊。詳細步驟如下：

1. 準備樣本：從資料集中隨機取出一張真實的人群分布圖 x_0 ，並生成一個與其維度相同的高斯雜訊圖 ϵ 。
2. 隨機加噪(前向過程)：隨機選擇一個時間步 t ，得益於擴散模型的數學特性，我們不需逐步迭代加噪，而是可以直接使用以下公式，一步到位地生成對應的噪音圖像：

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon \quad (1)$$

3. 訓練預測(反向過程)：將加噪後的圖像 x_t 以及當前的時間步 t 一同輸入到雜訊預測模型中。模型的目標是輸出一個預測雜訊 ϵ_t ，並透過計算其與原始真實雜訊 ϵ 之間的均方誤差(MSE)來進行學習與優化，如圖 19 第 t 個時間步的訓練過程

透過在所有時間步 t 重複此過程，模型最終將學會一個通用的去噪能力。




圖 19、反向過程第 t 時間步示意圖

推論：當模型訓練完成後，即可進行推論，以生成全新的圖。其過程是訓練的逆向操作，如圖 20 所示：

1. 起始：從一張與目標維度相同、由純高斯雜訊構成的隨機圖像 X_T 開始。
2. 迭代去噪：從最後一個時間步 T 開始，依序遞減至 $t = 1$ 。在每一個時間步 t ，將當前的圖像 x_t 輸入已訓練好的模型，預測出其中包含的雜訊，並從 x_t 中減去這個預測的雜訊，得到一張稍微乾淨一點的圖像 x_{t-1} 。
3. 注入隨機性：為了保證生成結果的多樣性，避免每次都生成同樣的圖片，在每一個去噪步驟中，還會額外加入一個微小的隨機雜訊。
4. 完成：當迭代至 $t=0$ 時，最初的隨機雜訊圖便會被逐步還原成一張全新的清晰且高品質的人群分布圖。




圖 20、最後時間步推論流程示意圖

本研究所採用的擴散模型，其具體實現為去噪擴散機率模型(Denoising Diffusion Probabilistic Model, DDPM)。圖 21 為本研究的 DDPM 架構設計，整體的 DDPM3D 模型包含一個作為雜訊預測核心的 UNet3D 網路，以及圍繞其外的擴散過程。在訓練或推論時，輸入的資料為兩張 20×20 網格矩陣張量(人流與重要影響特徵)，會與對應的時間步一同送入 UNet3D，而 DDPM 框架則負責管理完整的前向擴散加噪與反向擴散去噪流程，最後輸出一張 20×20 的人群分布網格。




圖 21、DDPM3D 架構圖

本研究的雜訊預測器採用了 U-Net 架構，其結構專為圖像到圖像的轉換任務設計，非常適合去噪任務。本研究 U-Net 模型架構設計如圖 22 所示：




圖 22、U-Net3D 架構圖

1. 輸入層(Input Layer)：融合情境的初始狀態

模型的輸入是由帶有雜訊的人群分布圖 x_t (維度 (1, 1, 20, 20))，以及包含時間、天氣、事件等重要影響特徵的「條件」Cond(從 2 通道擴展至 16 通道)在通道維度上合併而成。這個 (17, 1, 20, 20) 的初始張量，代表了「在特定情境下，一個帶有不確定性的人群分布狀態」，模型的核心任務便是利用豐富的條件資訊，來準確預測並移除其中的雜訊。

2. 編碼器 (Encoder)：從局部細節到全局語意的特徵提取

編碼器路徑透過四個區塊，以「空間尺寸減半、通道數加倍」的方式，逐步提取人群分布的多尺度特徵。其意義在於：

淺層編碼器 (Encoder 1-2): 在較高的空間解析度(20x20, 10x10)下操作，主要負責捕捉局部空間細節。例如，相鄰網格間的人流互動、小範圍人群的聚集紋理、或是道路邊界對人流的影響。

深層編碼器 (Encoder 3-4): 隨著解析度降低(5x5, 2x2)，感受野 (Receptive field) 變大，模型開始學習更抽象的全局語意資訊。它不再關注單一網格，而是判斷「這是否為一個大型節慶」、「這是否為交通尖峰時段的模式」等高層次概念。

3. 瓶頸層 (Bottleneck)：場景的全域語意壓縮

位於網路最深處的瓶頸層，將特徵圖壓縮至 (1024, 1, 1, 1)。此時，所有的空間資訊被壓縮到極致，形成一個高度濃縮的特徵向量。這個向量可以被理解為模型對整個場景的「一句話總結」，例如「一個雨天週末下午的信義商圈」，它捕捉了場景的「是什麼」(what)，但暫時忽略了「在哪裡」(where)。

4. 解碼器 (Decoder) 與跳躍連接 (Skip Connections)：

解碼器路徑的任務，是將瓶頸層的抽象語意「畫」回一張精細的人群分布圖。然而，僅靠抽象語意會導致位置模糊。

此時，跳躍連接扮演了關鍵角色：它將編碼器中，包含精確位置資訊的淺層特徵圖，直接傳遞給對稱的解碼器層。這個機制使得模型能結合「是什麼」(What) 的全局語意與「在哪裡」(Where) 的局部細節，從而生成邊緣清晰、位置準確的高解析度人群分布。

5. 時間嵌入(Time Embedding)：

時間步 t 透過嵌入層注入到 U-Net 的每個層級，這使得單一模型能根據當

前的雜訊水平 t ，動態調整其去噪策略。在 t 值高時(雜訊多)，模型專注於生成輪廓；在 t 值低時(雜訊少)，則專注於還原細節。

6. 輸出層 (Output Layer)：生成預測雜訊

最後，模型輸出的不是直接的人群圖，而是一個與輸入雜訊維度完全相同的「預測雜訊 $\varepsilon_{\text{pred}}$ 」。在擴散模型的框架下，我們能利用這個預測出的雜訊，從 x_t 中推導出去除一步雜訊後的 x_{t-1} ，並依此迭代，最終生成清晰的人群分布圖。

7. 根據上述參數設定，本研究所採用的 UNet3D 模型總參數量約為五千萬 (50M)

8. U-Net 編碼器與解碼器中的核心建構單元為 DoubleConv3D 卷積區塊，其結構為兩個連續的 3D 卷積層與批次歸一化(Batch Normalization)。在每個卷積層與批次歸一化之間，本研究採用 SiLU (Sigmoid-weighted Linear Unit) 作為激活函數。

相較於傳統深度學習模型中常用的 ReLU 激活函數，SiLU 具有數項優勢。ReLU 的公式為 $f(x) = \max(0, x)$ ，其在負值區間梯度為零的特性可能導致部分神經元永久失效(即「Dying ReLU」問題)。而 SiLU 的公式為 $f(x) = x \cdot \sigma(x)$ ，其曲線不僅處處平滑可微，有助於梯度優化，更具備「非單調性」的特點：在負值區間會先略微下降才回到零(如圖 23 所示)。此特性被認為能增加模型的表達能力，並避免神經元完全失效，因此在許多現代生成模型中，SiLU 已逐漸取代 ReLU 成為更佳的选择。




圖 23、ReLU 與 SiLU 函數示意圖

4.4 樹狀擴散模型

為了解決單一通用模型精度不足，以及多重獨立模型成本過高且忽略空間關聯性的兩難困境，本研究提出一個創新的樹狀擴散模型框架。即系統流程圖的第三部分(圖 24 為樹狀擴散模型建構流程)，此框架是一個階層式的生成模型，旨在透過預訓練-遷移學習的模式，讓模型從學習全域的共通模式，逐步專精到各個異質性分群的獨特模式，從而在精度與效率之間取得平衡。此框架的建立過程主要分為 Root、Branch、Leaf 三層模型的訓練。




圖 24、樹狀擴散模型建構流程圖

Root Model 是整個樹狀結構的基礎骨幹。其目標是學習整個台北市最通用、最宏觀的人群分布規律。它的訓練方式是一個條件式擴散模型，但其條件並非使用所有原始的輔助特徵，而是由 4.2 節的全地圖決策樹所決定，對全域數據最具區分度的前兩個特徵及其分裂閾值。透過這種方式，Root Model 專注於學習在最關鍵的全域因子影響下的基礎人流樣貌。此模型在完整的訓練集上進行訓練，其生成的模擬結果將作為下一階段 Branch Model 的重要輸入之一。

Branch Model 扮演著承先啟後的角色，負責在 Root Model 建立的基礎上進行初步的細化。此階段的核心技術是遷移學習 Transfer Learning。Branch Model 的結構與 Root Model 完全相同，其初始權重是直接由訓練完成的 Root Model 遷移而來，而非從零開始訓練。在本研究訓練時，Branch Model 會被劃分為兩個階段模型，也可視訓練資料的多寡或該城市特徵特性擴增階段數。第一階段模型的輸入條件，是全地圖決策樹中第三個重要特徵以及 Root Model 的模擬結果；第二階段模型的輸入條件，則是第四個重要特徵以及第一階段模型的模擬結果。透過這種階層式的條件輸入與權重遷移，Branch Model 能在繼承全域知識的同時，快速學習更細緻的模式，逐步深化模擬的精準度。

Leaf Model 是樹狀結構的最終層，代表了最高度專精的專家模型。每一個 Leaf Model 都負責一個特定的人群分布模式，其建立過程同樣採用遷移學習。Leaf Model 的初始權重由其對應的 Branch Mode 遷移而來。接著，每個 Leaf Model 會在其專屬條件群組進行微調(fine-tuning)。這些條件群組來自於先前透過 LightGBM 完成的三種分群結果：

網格特徵分群：基於每個網格最主要的影響因子所劃分的群組。

事件特徵分群：基於對特定事件(如演唱會)反應最敏感的網格所劃分的群組。

誤差情形分群：基於 Branch Model 模擬誤差特性所劃分的群組。

理論上，每一個群組中的子群都能對應到一個專屬的 Leaf Model，也會依實驗結果篩選掉不適合的特徵。在訓練時，模型的輸入為 Branch Model 的模擬結果以及該群組對應的重要影響因子。透過這種方式，Leaf Models 得以在繼承通用知識的基礎上，專注學習並精煉特定情境下的獨特人流細節，最終達成高效率與高精度的模擬目標。

4.5 Online 流程

當樹狀擴散模型的所有層級(Root, Branch, Leaf)在離線(Offline)階段完成訓練後，整個系統便具備了對未來任意時刻進行模擬的能力。此階段稱為線上(Online)流程，其核心是根據使用者提供的查詢條件，依循已建立的樹狀結構，進行一連串階層式的推論，最終生成目標情境的人群分布圖。




圖 25、Online 詳細流程結構示意圖

整個 Online 流程的執行步驟可對照圖 25 的詳細結構流程圖，具體闡述如下：

輸入查詢條件：首先，使用者可提供一至多組欲查詢的特徵資料，例如特定的日期、時間、預測的天氣狀況、以及是否有特殊事件等。

Root Model 推論：系統將使用者的查詢條件，首先匹配 Root Model 所依據的全域性關鍵特徵(例如圖 25 中的特徵 1 與特徵 2)。Root Model 會根據這些最高層級的特徵，生成一張全域性、基礎的人群分布預測圖。

Branch Model 階層式推論：Root Model 的生成結果，將連同下一個層級的關鍵特徵(如特徵 3)，一同作為輸入，傳遞給對應的 Branch Model 進行第一階段的推論。此過程可以是串聯的，例如 Branch 1 中的 Stage 1 模型會根據特徵 3 對結果進行精煉，其輸出再連同特徵 4 一同輸入 Stage 2 模型進行再次精煉。

Leaf Model 選擇與最終生成：經過 Branch Model 的階層式精煉後，系統會根據查詢條件中更細緻的特徵(例如由網格特徵分群、事件特徵分群或誤差情形分群所決定的特徵，特徵 5 至特徵 8)，從多個 Leaf Model 中選擇出最符合當前情境的那些專家模型。

輸出結果：被選中的那些 Leaf Model 會接收來自 Branch Model 的精煉結果作為輸入，執行最後、也最專精的去噪生成步驟。最終這些 Leaf Model 的輸出與 Branch Model 輸出組合，即為本次查詢的最終人群分布。

圖 26 為最終人群分布模擬示意圖，數字代表的是該條件下模擬出分布於該網人的人數，同樣顏色外框線代表同一個 Leaf Model 生成的結果，例如藍色代表的是小巨蛋活動 Leaf Model，無外框線則代表因為 Branch Model 所使用特徵已符合網格特性，因此直接使用其生成結果。




圖 26、最終人群分布模擬示意圖

4.6 評估標準

為了客觀且多面向地評估本研究所提出之樹狀擴散模型的性能，本節將定義詳細的比較方法與量化評估指標。比較方法旨在將本研究模型與不同基準進行

對照，以凸顯其相對優勢；評估指標則是用於從不同維度衡量模型生成結果的準確性與真實性。

比較方法：本研究設計了兩種比較方法，以全面性地評估 LeafModel 相較於其他模型的效益。所有比較都將在 Leaf Model 對應的特定數據子集上進行，以確保評估基礎的公平性。

1. 與 Baseline 模型比較：為驗證樹狀階層架構的優越性，我們將 LeafModel 與一個基準模型(Baseline Model)進行比較。此基準模型是一個單階段的擴散模型，模型架構與 Leaf Model 幾乎相同，唯一不同之處是它會直接使用所有相關的特徵作為輸入條件，意即輸入通道從原先的 2 通道變為 4 通道或以上(如圖 27 所示)，並在與 LeafModel 模型完全相同的數據子集上進行訓練。此比較旨在釐清階層式學習是否優於傳統的單一模型配適方法。




圖 27、Baseline 模型架構圖

2. 與 Branch Model 比較：旨在驗證本研究中由通用模型精煉至專家模型的有效性。我們將比較最終的 Leaf Model 與其上一層的 Branch Model 在相同測試數據上的表現，以量化最後一個階段的特徵分群與專業化訓練所帶來的性能提升幅度。

評估指標：本研究將採用以下六種量化指標，依序為 MSE, MAE, MAPE,

SMAPE, STDE, FID，來評估所有模型的生成結果。為更全面地分析誤差，其中部分指標將會以兩種不同的模式進行計算：Overall 與 AvgGrid。

1. Overall：此模式先將所有網格在所有時間點的誤差值匯總後，再進行一次性的平均計算。它反映的是模型在整體數據集上的宏觀平均表現。
2. AvgGrid：此模式首先針對單一網格，計算其在所有時間點的平均誤差，最後再將全部網格的平均誤差值進行第二次平均。此方法賦予每個網格相同的權重，更能反映模型在地理空間上的普遍性能。

評估所選特徵影響範圍是否符合預期，我們還將指標分析的結果分成三種類別：

1. Full Map: 即分析全地圖結果。
2. Filtered: 僅分析該 Leaf Model 所包含網格。
3. Filtered Expanded: 將 Leaf Model 包含之網格向周遭拓展出的 3x3 方形範圍。

在下列公式中，我們定義 n 為網格總數， T 為時間點總數， $y_{i,t}$ 為網格 i 在時間 t 的真實值， $\hat{y}_{i,t}$ 為對應的模擬值，而 ϵ 為避免分母為零的極小值。

具體指標定義如下：

1. 均方誤差 (Mean Squared Error, MSE)：計算模擬值與真實值之間差異的平方的平均。與 MAE 相比，MSE 會對較大的誤差(離群點)給予更重的懲罰。也是本研究訓練模型時的主要損失函數。

$$MSE = \frac{1}{n \cdot T} \sum_{i=1}^n \sum_{t=1}^T (y_{i,t} - \hat{y}_{i,t})^2 \quad (2)$$

2. 平均絕對誤差 (Mean Absolute Error, MAE)：計算模擬值與真實值之間差異

的絕對值的平均。此指標與人群尺度相同，能最直觀地反映預測誤差實際誤差情況。

$$MAE = \frac{1}{n \cdot T} \sum_{i=1}^n \sum_{t=1}^T |y_{i,t} - \hat{y}_{i,t}| \quad (3)$$

3. 平均絕對百分比誤差 (Mean Absolute Percentage Error, MAPE)：計算誤差在真實值中所佔的百分比的絕對值平均。此指標的優點是不受資料量綱影響，但缺點是在真實值接近零時會變得不穩定。此指標以 Overall 及 AvgGrid 兩種模式計算。

$$MAPE = \frac{100\%}{n \cdot T} \sum_{i=1}^n \sum_{t=1}^T \frac{|y_{i,t} - \hat{y}_{i,t}|}{y_{i,t} + \epsilon} \quad (4)$$

4. 對稱平均絕對百分比誤差 (Symmetric Mean Absolute Percentage Error, SMAPE)：MAPE 的改良版，透過將分母改為真實值與模擬值的絕對值平均，解決了真實值為零的問題，並使誤差的對稱性更好，值域在 0% 到 200% 之間。此指標以 Overall 及 AvgGrid 兩種模式計算。

$$SMAPE = \frac{100\%}{n \cdot T} \sum_{i=1}^n \sum_{t=1}^T \frac{|y_{i,t} - \hat{y}_{i,t}|}{(|y_{i,t}| + |\hat{y}_{i,t}|)/2 + \epsilon} \quad (5)$$

5. 標準化誤差 (Standardized Error, STDE)：本研究自定義指標，其計算方式為平均絕對誤差(MAE)除以真實數據的標準差 σ ，此指標旨在衡量模型的平均誤差相對於數據自然波動的大小，以 Overall 及 AvgGrid 兩種模式計算。

$$STDE = \frac{MAE}{\sigma} \quad (6)$$

6. Fréchet Inception 距離 (Fréchet Inception Distance, FID)：此指標用於評估生成圖像的品質與多樣性。它透過一個預訓練的 InceptionV3 模型提取真實圖像與生成圖像的特徵，並計算這兩組特徵在分布上的距離。FID 分數越低，代表生成圖像的整體品質與真實圖像越難以區分。此為全域性指標，不區分 Overall 與 AvgGrid，也沒有 Full Map、Filtered、Filtered Expanded 之差異。



國立中興大學

NATIONAL CHUNG HSING UNIVERSITY

第五章 實驗模擬

本章旨在呈現研究方法的具體實作過程與結果。內容將涵蓋實驗的軟硬體開發環境、各階段模型的參數設定、訓練過程，並對最終的模型性能進行詳細的量化評估與分析，以驗證本研究提出之「樹狀擴散模型」的有效性。

本研究所有實驗的訓練、推論與分析，皆在以下軟硬體環境中進行：

中央處理器 (CPU): Intel® Core™ i9-12900K、圖形處理器 (GPU): NVIDIA GeForce RTX 4090、記憶體 (RAM): 64 GB、作業系統 (OS): Windows 11、CUDA 版本: 12.6、程式語言框架: Python 3.9.13、深度學習框架: PyTorch 2.6.0。

為完整說明本研究框架的建構與驗證過程，本章節的論述結構如下。首先，為了驗證本研究樹狀框架骨幹的建構與成效，我們在 5.1 節將詳述如何利用 LightGBM 建構上層模型，並透過多種分析方式驗證其性能。為了說明本研究生成模型的核心，我們在 5.2 節將深入介紹擴散模型 (Diffusion Model) 的具體架構與參數設定。接著，為了驗證特化葉節點模型對於提升預測精度的效益，我們在 5.3 節將依據不同的分群策略建立並評估各組 LeafModel 的模擬成果。此外，為了深入探討事件因子在模型中的作用，我們在 5.4 節將特別針對「事件特徵分群」的結果進行討論與分析。最後，將在 5.5 節對本章所有實驗結果進行總結。

5.1 Diffusion Model 效能驗證

模型參數：樹狀結構中所有擴散模型的網路架構，均基於一組共享的超參數進行建置。這些參數定義了 U-Net 的複雜度、擴散過程的時間步長、以及條件編碼的維度等。詳細的模型參數設定如表 3 所示。

表 3、擴散模型參數表

參數	設定值
UNet 通道數	64
時間嵌入維度	64
條件特徵維度	16
時間步長	1000

訓練參數：我們採用了一致的優化器、學習率排程與早停機制，以確保各層級模型訓練過程的穩定性與可比較性。詳細的訓練參數設定如表 4 所示。

表 4、擴散模型訓練參數表

參數	設定值
epochs	64
Batch size	64
Drop rate	16
Learning rate max	0.0001
Learning rate min	1e-7
Early stopping patience	8

訓練情形：圖 28 展示了模型在訓練過程中的損失變化曲線。圖中的藍色線代表訓練集損失(Training Loss)，橘色線則代表驗證集損失(Validation Loss)，兩者皆使用均方誤差(MSE)作為評估指標。從圖中可以觀察到，在訓練初期，訓練與驗證損失都呈現快速下降的趨勢，這表明模型正在有效地從數據中學習人流分布的潛在模式。隨著訓練週期的增加，兩條曲線逐漸趨於平緩並收斂，顯示模型已達到一個穩定的狀態。值得注意的是，驗證集損失曲線與訓練集損失曲線的趨勢十分貼近，並未出現顯著的分歧，這代表模型具有良好的泛化能力，並未產生嚴重的過擬合現象。

實際效能方面，擴散模型在本研究的開發環境下，訓練時間為 1 至 3 分鐘 (Baseline 模型則是 1.5~5 分鐘)。而在推論(生成)階段，模型的生成速度約為每 100 個樣本需時 1 分鐘。意即在此開發環境下，每次僅需時 0.5 秒就能產生一份複數種指定條件下的全城市人群分布模擬結果。




圖 28、最終分群結果樹狀擴散模型示意圖

5.2 LightGBM 及樹狀骨幹效能驗證

如第四章所述，本研究的上層框架，即樹狀骨幹，是透過 LightGBM 及其產出的「全地圖決策樹」來引導 Root Model 與 Branch Model 的建立。本節將詳述 LightGBM 的參數設定、訓練過程，以及產出的全地圖決策樹，最後再評估分析以決策樹建模的 Root Model 以及 Leaf Model 骨幹。

LightGBM 模型的訓練，皆採用一組共享的核心超參數，以確保分析基礎的一致性。詳細的參數設定如表 5 所示。

表 5、LightGBM 模型參數表

參數	設定值
Boosting type	goss
Learning rate	0.01
Iterations	10000
Early stopping	10
leaves	31
Min data in leaf	20

全地圖通用決策樹: 圖 29 為模型訓練全地圖 LightGBM 模型的訓練曲線，從圖中可以看到在 700 多的迭代時就已經停止收斂，代表這 400 個網格難以僅透過一個模型完全捕捉人群分布的特徵。但我們因此能夠快速地得到一個宏觀的共通規律，並利用這些對全地圖泛化能力較高的特徵設計 Root Model 以及 Branch Model。




圖 29、全地圖 lightGBM 訓練曲線圖

圖 30 則顯示對全地圖而言最重要的特徵，以及特徵資料對預測結果的影響，我們可以明顯的發現最重要特徵是小時以及是否為假日兩項。




圖 30、全地圖 LightGBM SHAP 摘要及特徵重要度圖

並且從執行結果中 split gain 最大的決策樹(圖 31)也可以發現一樣的結論。我們之後將使用此樹中最大 split gain 路徑建構樹狀擴散框架。




圖 31、全地圖最大 split gain 決策樹(節錄)

該樹結果顯示，模型首先以 Hour 小於等於 8.5 將資料分成睡眠與清醒兩大類，接著再將清醒時間的人群分成假日與平日，而平日時間則被深夜以及一般時間給區隔開來，最後再把平日活動時間的人們分成小週末以及平常工作日。圖 32 為我們以此建立的樹狀擴散模型框架的骨幹。




圖 32、樹狀擴散模型框架骨幹

骨幹效果驗證：在建構完樹狀框架的骨幹(Root Model 與 Branch Model)後，為了深入了解其預測能力與極限，並為後續的葉節點模型提供修正依據，本研究對此骨幹模型進行了效果驗證。我們透過 Branch Model 模擬出完整資料集的人群分布，並與真實資料進行四種角度的分析：第一項分析是計算各網格的「累計人數誤差」(圖 33)，旨在評估誤差值總量較大的網格。結果顯示，較大的誤差主要集中在人流極度密集且變化快速的區域，如交通樞紐及核心商業區。接下來的三項分析則從不同維度，旨在找出表現不穩定的網格。其中，第二項分析計算了「人數誤差 > 100 之累計小時數」(圖 34)，用以評估容易產生大幅度單次誤差的網格。第三項與第四項分析則關注誤差的穩定性，分別計算了「累計標準差誤差」(圖 35)以及「標準差誤差 > 1 之累計小時數」(圖 36)，旨在找出誤差波動大且頻繁的網格。綜合圖 33 至圖 36 的結果，我們發現這些預測不穩定的網格，主要分布在具有潮汐特性或非規律人流的觀光郊區及交通要道。透過這四項分析，我們得以定位通用骨幹模型表現不佳的特定區域與情境，從而為後續的葉節點特化訓練提供了明確的方向。




圖 33、累計人數誤差




圖 34、人數誤差>100 之累計
小時數




圖 35、累計標準差誤差




圖 36、標準差誤差>1 之累計
小時數

5.3 Leaf Model 建模效能驗證

本節將聚焦於葉節點模型 (Leaf Models) 的特化訓練及其成效。如第四章所述，為了處理通用模型難以應對的特定情境，我們採用了三種不同的分群策略來將數據進行精細劃分。因此，本節將首先說明網格特徵分群、事件特徵分群、以及誤差情形分群的具體流程與劃分依據。隨後，將依序針對這三種策略所產生的分群結果，進行個別的 Leaf Model 建模，並展示其最終的模擬成果與比較

分析，以驗證此種特化訓練策略的有效性。

網格特徵分群: 完成 LightGBM 模型產生的全地圖決策樹後，為了進一步探勘各個網格的區域性特徵，我們將三個全地圖決策樹的全域特徵排除(hour, holiday, weekday)，並針對 400 個網格各自訓練獨立的 LightGBM 模型。圖 37 為其中一個網格特徵的訓練曲線，可以發現與全地圖時不同的是，模型訓練迭代次數從 700 增加到 10000，這代表模型已充分利用其容量，對訓練資料進行了最大程度的擬合；但另一方面，這也通常伴隨著較高的過擬合風險，這個現象也從側面印證了單純使用獨立網格建模的侷限性。雖然 10000 的迭代次數並不需花費太多的時間，但在此階段目的僅為獲得該網格最重要特徵，而非探究該網格人群分布的支微末節，建議將該超參數設為 1000 左右即可，以達成快速分群的效果。




圖 37、單一網格 LightGBM 訓練曲線圖

分群結果如表 6 所示，為避免失去分群意義，我們將排除涵蓋範圍過廣(如總雲量)或過少的群組(最大陣風、最大陣風風向)。

表 6、網格特徵分群表

規則	座標數量
總雲量 ≤ 0	158
紫外線指數 ≤ 0	62
月=1 2	18
最大陣風 ≤ 3.5	10
最大陣風風向 ≤ -0.7	9

事件特徵分群：此分析流程與前述的網格特徵分群相似，但有兩點關鍵不同，第一，我們將模型的輸入特徵，限定於不含地理位置的類別特徵，主要包含 holiday、weekday 等常規時間特徵，以及本研究關注的特殊事件特徵。具體而言，後者涵蓋了「小巨蛋活動」、「台北燈節」與「新北耶誕城」等事件是否發生的布林指標。第二，此分群的目標，是專門識別出那些人群分布與特定事件的發生高度相關的網格。換言之，我們要找出哪些網格會因為小巨蛋辦演唱會、或因為燈節及耶誕城的舉辦而出現顯著的人潮變化，以便後續為這些「事件驅動型」的網格建立專屬的 Leaf Model。

例如，圖 38 為對有無舉辦台北燈節較敏感的網格分布，表 7 為對有無舉辦小巨蛋活動敏感網格的分群結果。




圖 38、台北燈節敏感網格分布圖

規則	座標數量
ArenaEvents	27
Concert	22

表 7、小巨蛋活動分群表

誤差情形分群: 我們從 5.2 節分析了框架骨幹的四種誤差情形，再將四種分析各建立四種分群(正向誤差 Top k、正向誤差其餘、負向誤差 Top k、負向誤差其餘)，共有 16 種分群結果，本實驗模擬章節僅以其中兩個分群結果，包含圖 39 的累計人數誤差 Top50 以及圖 40 的標準差誤差 > 1 之累計小時數 Top20 為範例。




圖 39、累計人數誤差 Top50
(深紅色網格)

圖 40、標準差誤差>1 之累
計小時數 Top20(深紅色網格)

最終分群結果建立之樹狀擴散模型架構如圖 41 所示




圖 41、最終分群結果樹狀擴散模型示意圖

網格特徵分群策略模擬結果:

LeafModel 1(月==1||2): 從表 8 及圖 42 可以看出 LeafModel 1 不論何種指標都較 Baseline 優異。而他的分群範圍(Filtered)以及其周遭(Filtered Expanded)也在大部分指標更優於全地圖。證明此特徵在階層式模型較直接單一擴散模型更佳。

表 8、Leaf Model 1 實驗模擬結果(Leaf1 - Baseline)

Leaf1 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-80939	-976520	-1296894
MAE	-366	-356	-466
MAPE (AvgGrid)	-45.6	-107	-52.1
SMAPE (AvgGrid)	-22.1	-18.6	-21.5
MAPE (Overall)	-16.9	-18.6	-18.3
SMAPE (Overall)	-18.4	-17.7	-20.3
STDE (AvgGrid)	-1.24	-2.68	-1.31
STDE (Overall)	-0.18	-0.30	-0.22
FID	-76.3	-76.3	-76.6




圖 42、Leaf Model 1 實驗模擬結果(Leaf1 - Baseline)

而表 9 及圖 43 則顯示 Leaf Model 1 各種指標皆在其涵蓋範圍有最好的成績，且也都優於 Branch Model。由此可見特徵選擇及分群結果都有達到預期的效果

表 9、Leaf Model 1 實驗模擬結果(Leaf1 - Branch)

Leaf1 - Branch	Full Map	Filtered	Filtered Expanded
MSE	44640	-223577	67773
MAE	-79.4	-314	-95.1
MAPE (AvgGrid)	-9.06	-19.6	-7.17
SMAPE (AvgGrid)	-8.78	-16.8	-6.37
MAPE (Overall)	-3.68	-16.62	-3.75
SMAPE (Overall)	-3.37	-14.52	-3.38
STDE (AvgGrid)	-0.28	-0.65	-0.23
STDE (Overall)	-0.04	-0.27	-0.04
FID	-14.5	-14.5	-14.5




圖 43、Leaf Model 1 實驗模擬結果(Leaf1 -Branch)

Leaf Model 2 (紫外線>0)：從表 10 可見，雖然部分指標 Filtered 最優，但也有些指標是最差的結果，推測主要原因在於此分群涵蓋範圍太廣未能有效形成一個具備獨特性的分群(圖 44、及 45)。儘管如此，將 Leaf Model 2 與 Baseline 相比，仍可見幾乎所有指標都比 Baseline 更佳，證明階層式架構模擬效果仍然更優越。從此實驗模擬結果，我們發現未來可能的改進兩個方向，一是以比例的方式限制每個分群的範圍，或是額外構思系統性的分群拆分合併規則等兩個面向改進。

表 10、Leaf Model 2 實驗模擬結果(Leaf2 - Baseline)

Leaf2 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-39683	44061	-62733
MAE	-85.4	-66.22	-91.8
MAPE (AvgGrid)	-10.1	-14.0	-9.86
SMAPE (AvgGrid)	-8.30	-8.52	-8.15
MAPE (Overall)	-3.53	-2.64	-3.65
SMAPE (Overall)	-3.72	-2.80	-3.86
STDE (AvgGrid)	-0.36	-0.51	-0.35
STDE (Overall)	-0.04	-0.03	-0.04
FID	-9.84	-9.84	-9.84




圖 44、Leaf Model 2 實驗模擬結果(Leaf2 -Baseline)

再進一步檢視表 10 處，雖然大部分指標都是 Filtered 較優，但 MSE 指標卻是 Leaf 比 Branch 更差。我們推論此現象源於特徵之間的共線性，由於 Leaf Model 2 所使用的特徵紫外線其數值變化與 Branch Model 已包含的特徵小時存在高度相關性，這意味著紫外線這個特徵為模型提供的新資訊相對有限，未能有效引導模型進行更深層次的學習。從此研究模擬，我們認為未來需要建立自動化的特徵篩選方法，包含檢視各特徵的關聯性、挑選排除共線特徵。

表 11、Leaf Model 2 實驗模擬結果(Leaf2 - Branch)

Leaf2 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	86511	80182	93890
MAE	-73.5	-77.2	-71.3
MAPE (AvgGrid)	-7.69	-7.85	-7.14
SMAPE (AvgGrid)	-8.53	-9.10	-7.63
MAPE (Overall)	-3.04	-3.08	-2.83
SMAPE (Overall)	-3.03	-3.21	-2.85
STDE (AvgGrid)	-0.26	-0.26	-0.25
STDE (Overall)	-0.04	-0.04	-0.03
FID	-10.7	-10.7	-10.7




圖 45、Leaf Model 2 實驗模擬結果(Leaf2 - Branch)

事件特徵分群策略模擬結果:

Leaf Model 3(小巨蛋活動): 表 12 及圖 46 顯示 Leaf Model 3 不論何種指標都較 Baseline 優異。而大部分指標在分群範圍以及其周遭也比全地圖稍佳，可證明此樹狀擴散模型表現較單一擴散模型更優異。

表 12、Leaf Model 3 實驗模擬結果(Leaf3 - Baseline)

Leaf3 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-986336	-652944	-1E+06
MAE	-444	-376	-444
MAPE (AvgGrid)	-45.1	-72.5	-53.4
SMAPE (AvgGrid)	-26.0	-26.7	-27.0
MAPE (Overall)	-20.4	-18.7	-21.3
SMAPE (Overall)	-22.2	-20.2	-23.1
STDE (AvgGrid)	-1.32	-1.96	-1.51
STDE (Overall)	-0.22	-0.24	-0.24
FID	-87.6	-87.6	-87.6




圖 46、Leaf Model 3 實驗模擬結果(Leaf3 - Baseline)

表 13 顯示在與 Branch Model 的比較中，Leaf Model 3 在其所屬範圍除了 MSE 稍差以外，其餘指標皆較佳，而圖 47 雖然有小部分綠點，但從尺度量級看都是極小數字的誤差，表示分群結果有發揮其作用。

表 13、Leaf Model 3 實驗模擬結果(Leaf3 - Branch)

Leaf3 - Branch	Full Map	Filtered	Filtered Expanded
MSE	69727	5396	61158
MAE	-14.3	-31.9	-17.3
MAPE (AvgGrid)	-5.51	-8.66	-5.59
SMAPE (AvgGrid)	-5.05	-7.37	-4.61
MAPE (Overall)	-0.66	-1.59	-0.83
SMAPE (Overall)	-0.60	-1.60	-0.79
STDE (AvgGrid)	-0.17	-0.31	-0.18
STDE (Overall)	-0.01	-0.02	-0.01
FID	-5.76	-5.76	-5.76




圖 47、Leaf Model 3 實驗模擬結果(Leaf3 - Branch)

Leaf Model 4(小巨蛋演唱會): 所有指標皆是較 Baseline Model 優異，且最佳指標幾乎都在分群範圍(表 14)，可見樹狀架構表現較單一模型更佳。

表 14、Leaf Model 4 實驗模擬結果(Leaf4 - Baseline)

Leaf3 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-1478099	-1093127	-1004081
MAE	-660	-663	-629
MAPE (AvgGrid)	-83.6	-183	-119
SMAPE (AvgGrid)	-38.7	-45.8	-43.2
MAPE (Overall)	-30.7	-32	-34.1
SMAPE (Overall)	-32.8	-37.4	-35.1
STDE (AvgGrid)	-2.39	-4.17	-2.93
STDE (Overall)	-0.33	-0.49	-0.45
FID	-105	-105	-105




圖 48、Leaf Model 4 實驗模擬結果(Leaf4 - Baseline)

雖然與 Baseline 的比較並無異狀，然而根據表 15 的數據，此模型在多數誤差指標上的性能，雖均優於其上層，但在 MSE 與 MAPE 這兩項指標上，結果卻顯示 Branch 的誤差反而較低。再經由視覺化結果(圖 49)，我們發現此現象主要源於單一網格點的極端預測誤差，從而拉高了整體的平均指標，造成了看似矛盾的評估結果。未來的兩個潛在優化方向：第一，探索如何更細緻地劃分分群範圍，以將此類 outlier 獨立出來進行專門建模；第二，建立一套系統化的方法來識別並此類極端誤差網格，以獲得對模型普遍性能更穩健的評估。

表 15、Leaf Model 4 實驗模擬結果(Leaf3 - Branch)

Leaf3 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	153545	313	38242
MAE	-19.8	-8.70	2.26
MAPE (AvgGrid)	-2.86	4.43	-0.55
SMAPE (AvgGrid)	-3.66	-9.41	-2.76
MAPE (Overall)	0.92	-0.46	-0.12
SMAPE (Overall)	1.06	-0.48	-0.14
STDE (AvgGrid)	-0.09	-0.003	-0.05
STDE (Overall)	0.01	-0.006	-0.001
FID	-5.14	-5.14	-5.14




圖 49、Leaf Model 4 實驗模擬結果(Leaf4 - Branch)

誤差情形分群策略模擬結果:

Leaf Model 5(標準差誤差> 1 之累計小時數 TOP20，月>=10): 觀察表 16 可以發現到各項指標 Filtered 範圍時的表現皆為 Leaf Model 5 較 Baseline Model 佳，代表樹狀擴散模型優於單一擴散模型。然而在這些網格以外的則未必如此，綜合圖 50 視覺化結果更可明確看出 Filtered 以外部分網格為 Baseline Model 結果較好，表示此分群策略能十分有效的將特徵影響範圍完整區隔。

表 16、Leaf Model 5 實驗模擬結果(Leaf5 - Baseline)

Leaf5 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	181558	-5340	62876
MAE	48.3	-25.17	8.38
MAPE (AvgGrid)	-2.57	-27.4	-9.22
SMAPE (AvgGrid)	-0.28	-8.63	-3.23
MAPE (Overall)	2.15	-8.84	0.69
SMAPE (Overall)	2.20	-7.56	0.84
STDE (AvgGrid)	-0.09	-0.74	-0.29
STDE (Overall)	0.02	-0.12	0.01
FID	-3.42	-3.42	-3.42




圖 50、Leaf Model 5 實驗模擬結果(Leaf5 - Baseline)

再看到與 Branch Model 的比較(表 17 及圖 51)，各指標的情形也與 Baseline 情況雷同，再一次證明該分群效果卓越。

表 17、Leaf Model 5 實驗模擬結果(Leaf5 - Branch)

Leaf5 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	192485	-13304	65010.4
MAE	24.6	-65.0	-13.9
MAPE (AvgGrid)	-3.21724	-50.4	-12.1
SMAPE (AvgGrid)	-2.19	-8.23	-8.84
MAPE (Overall)	1.09	-22.8	-1.15
SMAPE (Overall)	1.28	-15.1	-0.92
STDE (AvgGrid)	-0.10	-1.39	-0.38
STDE (Overall)	-0.01	-0.32	-0.01
FID	-7.91	-7.91	-7.91




圖 51、Leaf Model 5 實驗模擬結果(Leaf5 - Branch)

Leaf Model 6(累計人數誤差 Top50，相對溼度 ≤ 67.5): 檢視表 18 後發現各指標結果與 Leaf2 情況相當類似，再透過圖 52 的觀察，就能明顯的發現一樣有分群範圍過廣的問題。但綜合各指標的結果，還是可以確認階層式框架更優於單一模型表現。

表 18、Leaf Model 6 實驗模擬結果(Leaf6 - Baseline)

Leaf6 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	35278	8155	18220
MAE	-28.5	-25.4	-29.3
MAPE (AvgGrid)	-7.60	-7.78	-9.37
SMAPE (AvgGrid)	-6.21	-8.81	-7.44
MAPE (Overall)	-1.18	-1.32	-1.25
SMAPE (Overall)	-1.25	-1.39	-1.32
STDE (AvgGrid)	-0.24	-0.21	-0.29
STDE (Overall)	-0.01	-0.01	-0.01
FID	-5.89	-5.89	-5.89




圖 52、Leaf Model 6 實驗模擬結果(Leaf6 - Baseline)

上一個比較發現分群範圍過大的問題，然而觀察表 19 的與 Branch 比較卻沒那麼明顯(應是範圍過大導致平均後的指標結果看起來正常)，但再看到視覺化結果的圖 53 又能明確觀察到綠點較多，且部分綠點的刻度量級已經接近紅點，再次確認分群方法上還有需要改進的空間。我們初步建議在以誤差情形做分群時，Top K 的 K 取值應該要小於全地圖的網格數量的 1/10 且大於 1/40，然而實際上須要經過詳細的研究驗證再訂定相關規則為佳。

表 19、Leaf Model 6 實驗模擬結果(Leaf6 - Branch)

Leaf6 - Branch	Full Map	Filtered	Filtered Expanded
MSE	146311	48858	1322120
MAE	-10.0	-48.5	-14.7
MAPE (AvgGrid)	-4.55	-15.9	-6.48
SMAPE (AvgGrid)	-5.60	-9.19	-7.82
MAPE (Overall)	-0.41	-2.51	-0.63
SMAPE (Overall)	-0.40	-2.24	-0.61
STDE (AvgGrid)	-0.15	-0.47	-0.21
STDE (Overall)	-0.01	-0.03	-0.01
FID	-6.46	-6.46	-6.46




圖 53、Leaf Model 6 實驗模擬結果(Leaf6 - Branch)

5.4 事件特徵分群效能驗證

前述章節中，本研究提出了三種用以建構 LeafModels 的分群策略，分別是基於網格主要影響因子的「網格特徵分群」、基於模型預測誤差的「誤差情形分群」、以及本節將深入探討的「事件特徵分群」。相較於前兩者分別處理了常態性的環境因子與模型的系統性偏差，「事件特徵分群」更專注於捕捉由特定活動

引發的、非週期性的劇烈人流變化，此類現象在過往研究中較少被深入量化。因此，本節將透過實驗結果，分析此分群策略在不同事件與地點上的成效，並探討其所揭示的區域人流特性。

台北燈節(Leaf Model 7)：本實驗旨在探討，當符合條件的資料筆數極少時，是否仍能有效訓練模型並進行準確推論與模擬。

透過表 20 與圖 54 可發現，本研究所採用的樹狀擴散模型在模擬人群分布結果的精確度方面，顯著優於 Baseline Model。其主要原因在於，單一擴散模型難以以極少量的資料完成有效訓練，而本研究提出的階層式架構能透過 Root Model 與 Branch Model 先行捕捉城市人群分布的大致趨勢。因而，即便最終可用的歷史資料相當稀少，仍可準確模擬出符合設定條件的人群分布情形。

表 20、Leaf Model 7 實驗模擬結果(Leaf7 - Baseline)

Leaf7 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-13879085	-16336588	-13379682.38
MAE	-1929	-1930	-1904
MAPE (AvgGrid)	-333	-362	-253.6
SMAPE (AvgGrid)	-71.6	-72.6	-71.0
MAPE (Overall)	-81.2	-83.4	-78.5
SMAPE (Overall)	-73.7	-75.1	-72.8
STDE (AvgGrid)	-9.66	-10.1	-7.23
STDE (Overall)	-0.96	-1.39	-1.01
FID	-108	-108	-108




圖 54、Leaf Model 7 實驗模擬結果(Leaf7 - Baseline)

進一步觀察表 21，我們發現，在 LeafModel 7 所涵蓋的區域內，LeafModel 顯著修正了 Branch Model 先前模擬偏差的問題；而在該區域以外的範圍，Branch Model 則展現出更佳的模擬效果，表示針對台北燈節事件因子的分群策略十分有效，所涵蓋群體中的網格整體而言對該因子展現高度敏感性。不過如圖 55 的左子圖所示，仍可見部分低數值的綠色網格。儘管對整體指標的影響有限，但也顯示分群範圍過於龐大，在精確度上仍有進一步優化的空間。

表 21、Leaf Model 7 實驗模擬結果(Leaf7 - Branch)

Leaf7 - Branch	Full Map	Filtered	Filtered Expanded
MSE	434272	-43562	295660
MAE	94.7	-83.8	59.4
MAPE (AvgGrid)	3.35	-1.59	2.70
SMAPE (AvgGrid)	2.47	-7.32	1.83
MAPE (Overall)	3.99	-3.62	2.45
SMAPE (Overall)	0.05	-4.28	2.22
STDE (AvgGrid)	0.05	-0.18	0.02
STDE (Overall)	-0.01	-0.06	0.03
FID	-2.80	-2.80	-2.80




圖 55、Leaf Model 7 實驗模擬結果(Leaf7 – Branch Model)

新北耶誕城(Leaf Model 8)：本實驗旨在探討，當事件發生地位於目標模擬人群分布範圍以外的城市時，模型的模擬效能表現如何。

從表 22 的各項指標中可見，Leaf Model 在多項評估結果上均大幅超越 Baseline Model，顯示在面對特殊事件時，階層式擴散模型的架構有效彌補了單一模型的不足，即便事件發生地未位於目標模擬之範圍內。

表 22、Leaf Model 8 實驗模擬結果(Leaf8 - Baseline)

Leaf8 - Baseline	Full Map	Filtered	Filtered Expanded
MSE	-1863878	-670215	-1704937
MAE	-719	-492	-677
MAPE (AvgGrid)	-84.7	-37.2	-77.3
SMAPE (AvgGrid)	-37.3	-32.8	-35.3
MAPE (Overall)	-31.8	-25.2	-30.3
SMAPE (Overall)	-34.4	-26.2	-32.7
STDE (AvgGrid)	-2.32	-1.65	-2.10
STDE (Overall)	-0.36	-0.39	-0.36
FID	-130	-130	-130




圖 56、Leaf Model 8 實驗模擬結果(Leaf8 - Baseline)

最後從表 23 可見，修正效果最佳的位置均集中分布於分群區域內。從圖 57 也能明確辨識出，在篩選範圍內幾乎皆為紅色網格，反映出 Leaf 的模擬結果具有顯著改善；而當範圍擴大後，則開始出現綠色網格，代表 Branch 在該區域表現相對更佳。進一步驗證即使特殊事件發生於原先模擬地圖的覆蓋範圍之外，樹狀擴散架構與分群策略，依然能在對應區域內產生精確且具體的模擬成效。

表 23、Leaf Model 8 實驗模擬結果(Leaf8 - Branch)

Leaf8 - Branch	Full Map	Filtered	Filtered Expanded
MSE	59158	-41381	36647
MAE	-43.4	-121.4	-58.8
MAPE (AvgGrid)	-7.20	-11.2	-9.36
SMAPE (AvgGrid)	-6.06	-12.6	-6.22
MAPE (Overall)	-1.92	-6.23	-2.63
SMAPE (Overall)	-1.92	-6.26	-2.62
STDE (AvgGrid)	-0.21	-0.40	-0.26
STDE (Overall)	-0.02	-0.10	-0.03
FID	-7.11	-7.11	-7.11




圖 57、Leaf Model 8 實驗模擬結果(Leaf8 – Branch Model)

5.5 實驗小結

綜合以上實驗結果，我們可以歸納出三點結論。

首先在 Leaf Model 與 Baseline Model 的比較中，分群涵蓋範圍內幾乎所有指標都顯示 Leaf Model 優於 Baseline Model，這充分表明了我們提出的樹狀擴散模型框架其模擬能力確實勝過單一擴散模型。

其次，與 Branch Model 的比較，我們也可以觀察到在分群涵蓋的範圍內，大部分的指標也是 Leaf Model 較佳，此結果驗證了使用 LightGBM 模型對地圖進行特徵分群，以訓練專家模型的策略顯具有效性。

最後，實驗結果也顯示了，針對單一擴散模型無法獨立建模的少量資料特殊事件，透過本研究提出的階層式方法依然能得到良好的人群分布模擬之結果。不只有良好的推論效能，也同時具有極佳的訓練資料利用效率。

儘管如此，我們仍然從實驗結果探索出未來研究的可行改進方向如以下幾點：

1. 分群規模最佳化: 實驗結果顯示, 若單一群組包含過多網格可能導致獨特性不足, 過少網格則可能導致模型難以穩健訓練, 均會影響專家模型的最終效益。

因此, 建立一套系統性的分群規模上下限規則, 或探索更動態的群組合併與拆分策略, 是後續研究的重要方向之一。

2. Leaf Model 特徵篩選機制: 我們發現若 Leaf Model 所使用的專精化特徵與其上層模型已使用的特徵存在共線性, 可能會限制 Leaf Model 的學習成效。

儘管能透過採用人工經驗法則進行篩選, 但若要將此研究發展為一個完善的系統, 勢必要建立能自動化識別並篩選冗餘特徵的機制。是使此框架成為一套完整系統的關鍵。

3. 極端網格處理: 從 Leaf Model 4 的實驗中可以觀察到, 單一網格的極端預測偏差, 會對整體平均指標造成不成比例的負面影響。

因此, 未來研究可著重於如何更謹慎地處理網格分群, 並構思如何系統性地自動識別此類極端網格並加以處理, 或是尋思一個新的加權評估指標。期望能更公平地評估模型性能, 並提升整體的模擬準確度。

第六章 結論

本論文旨在解決大規模都市人群分布模擬中，單一模型難以適應區域異質性，而多重模型成本過高的核心挑戰。為此，我們提出並實作了一個創新的「樹狀擴散模型」框架。此框架首先藉助 LightGBM 模型，從「全域特徵」、「網格特徵」、「事件特徵」以及「模型誤差」等多個維度，對複雜的時空數據進行自動化的分析與分群。接著，基於此分群結果，透過預訓練一個通用的 Root Model，並以遷移學習的方式，將其學習到的共通知識，高效地傳遞給專精於特定數據子集的 Branch Models 與 Leaf Models。實驗結果證明，本研究提出的階層式框架是成功的。在與扁平化設計的 Baseline 模型比較中，我們的專家模型(Leaf Models)在各項評估指標上均展現出顯著的優越性，驗證了階層式架構的有效性。同時，Leaf Models 相較於其上層的 Branch Model 的性能提升，也證明了以 LightGBM 進行特徵分群，以引導專家模型進行針對性學習的策略是可行的。

本研究的主要貢獻可歸納為以下三點：

1. 提出創新的「樹狀擴散模型」：本研究有效地結合了決策樹的數據劃分能力與擴散模型的生成能力，提出了一個全新的階層式生成框架，為複雜的時空數據模擬提供了新的解決方案。
2. 解決效率與精度的權衡困境：透過「通用模型預訓練」與「專家模型微調」的模式，本框架成功地在單一模型的低效率與多重模型的高成本之間，取得了一個優異的平衡點。
3. 實現稀疏數據的有效學習：利用遷移學習機制，使得樣本數較少、難以獨立建模的特定情境(如特殊活動)，也能夠在繼承通用知識的基礎上進行有效訓練，成功解決了稀疏數據的建模挑戰。

未來展望包含以下四點：

1. 自動化之特徵篩選機制：在部分實驗中，我們發現若 Leaf Model 所使用的專精化特徵與其上層模型已使用的特徵存在共線性，可能會限制其學習成效。目前研究採用人工經驗法則進行篩選，但為將此框架發展為更完善的系統，未來可研究建立一套能自動化分析特徵關聯性、並篩選冗餘特徵的機制，以提升模型的穩健性與自動化程度。
2. 分群規模之最適化：實驗結果顯示，若單一群組包含過多網格(可能導致獨特性不足)或過少網格(可能導致模型難以穩健訓練)，均會影響專家模型的最終效益。因此，未來可探索建立一套系統性的分群規模上下限規則，或發展更動態的群組合併與拆分策略，以確保每個專家模型都能在最適切的數據規模上進行訓練。
3. 極端誤差網格之處理：從實驗中可以觀察到，單一網格的極端預測偏差，會對 MSE 等敏感的整體指標造成不成比例的負面影響。未來研究可著重於構思如何系統性地自動識別此類極端網格並加以處理(例如，將其視為獨立分群或在評估時進行特殊加權)，以獲得對模型普遍性能更穩健、更客觀的評估。
4. 線上學習與模型更新機制：目前本研究的模型為離線訓練。為使系統能適應城市不斷變化的模式，未來可研究在此框架下引入線上學習(Online Learning)機制，讓模型能夠根據最新生成的即時數據，動態地進行微調與更新，以維持其長期預測的準確性。

參考書目

- [1] A. Ali, Y. Zhu, and M. Zakarya, "Exploiting dynamic spatio-temporal correlations for citywide traffic flow prediction using attention based neural networks," *Information Sciences*, vol. 577, pp. 852-870, 2021.
- [2] F. Amato, W. Gu, A. D'Acierno, and V. Moscato, "A novel framework for spatio-temporal prediction of climate and environmental data using deep learning," *Scientific Reports*, vol. 10, Art. no. 22011, 2020.
- [3] A. Arnberger and W. Haider, "A comparison of global and actual measures of perceived crowding of urban forest visitors," *Journal of Leisure Research*, vol. 39, no. 4, pp. 668-685, 2007.
- [4] D. Babu Sam, S. Surya, and R. Venkatesh Babu, "Switching convolutional neural network for crowd counting," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2017, pp. 5744-5752.
- [5] D. Bau, J.-Y. Zhu, J. Wulff, W. Peebles, H. Strobelt, B. Zhou, and A. Torralba, "Seeing what a GAN cannot generate," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2019, pp. 4501-4510.
- [6] T. Bhattacharya, L. Kulik, and J. Bailey, "Automatically recognizing places of interest from unreliable GPS data using spatio-temporal density estimation and line intersections," *Pervasive and Mobile Computing*, vol. 19, pp. 86-107, 2015.
- [7] D. Birant and A. Kut, "ST-DBSCAN: An algorithm for clustering spatial-temporal data," *Data & Knowledge Engineering*, vol. 60, no. 1, pp. 208-221, 2007.
- [8] L. BooMinathan, S. S. Kruthiventi, and R. V. Babu, "Crowdnet: A deep convolutional network for dense crowd counting," in *Proc. 24th ACM Int. Conf. Multimedia*, 2016, pp. 640-644.
- [9] M. Cardia, M. Luca, and L. Pappalardo, "Enhancing crowd flow prediction in various spatial and temporal granularities," *arXiv preprint arXiv:2203.07372*, 2022.
- [10] F. J. Chang, L. C. Chang, C. C. Kang, Y. S. Wang, and A. Huang, "Explore spatio-temporal PM2.5 features in northern Taiwan using machine learning techniques," *Science of the Total Environment*, vol. 736, Art. no. 139656, 2020.
- [11] K. Cheng, E. K. Lubamba, and Q. Liu, "Action prediction based on partial video observation via context and temporal sequential network with deformable convolution," *IEEE Access*, vol. 8, pp. 133527-133540, 2020.

- [12] H. Chen, J. Ding, Y. Li, Y. Wang, and X.-P. Zhang, "Social physics informed diffusion model for crowd simulation," *arXiv preprint arXiv:2402.06680*, 2024.
- [13] H. Chen, S. Yu, F. Huang, B. Zhu, L. Gao, and C. Qian, "Spatiotemporal analysis of retail customer behavior based on clustering and sequential pattern mining," in *Proc. 3rd Int. Conf. Artif. Intell. Big Data (ICAIBD)*, 2020, pp. 284-288.
- [14] J. Chen, W. Li, H. Zhang, W. Jiang, W. Li, Y. Sui, et al., "Mining urban sustainable performance: GPS data-based spatio-temporal analysis on on-road braking emission," *Journal of Cleaner Production*, vol. 270, Art. no. 122489, 2020.
- [15] Y. Chen, X. Zou, K. Li, K. Li, X. Yang, and C. Chen, "Multiple local 3D CNNs for region-based prediction in smart cities," *Information Sciences*, vol. 542, pp. 476-491, 2021.
- [16] K. B. Chimwayi and J. Anuradha, "Clustering West Nile Virus spatio-temporal data using ST-DBSCAN," *Procedia Computer Science*, vol. 132, pp. 1218-1227, 2018.
- [17] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21-27, 1967.
- [18] Y. Deng, J. Wang, C. Gao, X. Li, Z. Wang, and X. Li, "Assessing temporal-spatial characteristics of urban travel behaviors from multiday smart-card data," *Physica A: Statistical Mechanics and its Applications*, vol. 576, Art. no. 126058, 2021.
- [19] P. Dhariwal and A. Nichol, "Diffusion models beat GANs on image synthesis," *Advances in Neural Information Processing Systems*, vol. 34, pp. 8780-8794, 2021.
- [20] J. Feng, Z. Yang, F. Xu, H. Yu, M. Wang, and Y. Li, "Learning to simulate human mobility," in *Proc. 26th ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2020, pp. 3426-3433.
- [21] X. Feng, X. Ling, H. Zheng, Z. Chen, and Y. Xu, "Adaptive multi-kernel SVM with spatial-temporal correlation for short-term traffic flow prediction," *IEEE Transactions on Intelligent Transportation Systems*, vol. 20, no. 6, pp. 2001-2013, 2018.
- [22] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *Annals of Statistics*, vol. 29, no. 5, pp. 1189-1232, 2001.
- [23] V. X. Gong, W. Daamen, A. Bozzon, and S. P. Hoogendoorn, "Crowd characterization for crowd management using social media data in city events," *Travel Behaviour and Society*, vol. 20, pp. 192-212, 2020.

- [24] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, et al., “Generative adversarial nets,” *Advances in Neural Information Processing Systems*, vol. 27, 2014.
- [25] X. Guan, C. Fang, C. Dong, and S. Lu, “Application of fuzzy comprehensive clustering in urban land gradation based on data field,” in *Proc. 2010 IEEE Youth Conf. Inf. Comput. Telecommun.*
- [26] Q. Guan, S. Feng, and Y. Cao, “Clustering analysis of space 149 reconnaissance intelligent service requirements in presence of military values,” in *Proc. 2011 Second Int. Conf. Mech. Autom. Control Eng.*, 2011, pp. 3951-3953.
- [27] R. He, Y. Liu, Y. Xiao, X. Lu, and S. Zhang, “Deep spatio-temporal 3D densenet with multiscale ConvLSTM-Resnet network for citywide traffic flow forecasting,” *Knowledge-Based Systems*, Art. no. 109054, 2022.
- [28] J. Ho, A. Jain, and P. Abbeel, “Denoising diffusion probabilistic models,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 6840-6851, 2020.
- [29] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735-1780, 1997.
- [30] Y. Jianzhuo, Q. Mengyao, F. Liying, W. Ying, and Y. Jianyun, “Forecast the distribution of urban water point by using improved DBSCAN algorithm,” in *Proc. 2013 Third Int. Conf. Intell. Syst. Des. Eng. Appl.*, 2013, pp. 784-786.
- [31] R. Jiang, X. Song, D. Huang, X. Song, T. Xia, Z. Cai, et al., “Deepurbanevent: A system for predicting citywide crowd dynamics at big events,” in *Proc. 25th ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2019, pp. 2114-2122.
- [32] S. Jiang, S. Wang, Z. Li, W. Guo, and X. Pei, “Fluctuation similarity modeling for traffic flow time series: a clustering approach,” in *Proc. 2015 IEEE 18th Int. Conf. Intell. Transp. Syst.*, 2015, pp. 848-853.
- [33] S. Kartal and S. Erturk, “Assessment of the spatiotemporal prediction capabilities for sea surface temperature by deep learning methods,” *Knowledge-Based Systems*, vol. 268, Art. no. 110594, 2023.
- [34] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, et al., “LightGBM: A highly efficient gradient boosting decision tree,” *Advances in Neural Information Processing Systems*, vol. 30, pp. 3146-3154, 2017.
- [35] H. Lin, Y. Wang, M. Huo, C. Peng, Z. Liu, and M. Tomizuka, “Joint pedestrian trajectory prediction through posterior sampling with diffusion models,” *arXiv preprint arXiv:2404.00237*, 2024.

- [36] Z. Lin, J. Feng, Z. Lu, Y. Li, and D. Jin, "DeepSTN+: Context-aware spatial-temporal neural network for crowd flow prediction in metropolis," in *Proc. AAAI Conf. Artif. Intell.*, vol. 33, pp. 1020–1027, 2019.
- [37] M. Mirza and S. Osindero, "Conditional generative adversarial nets," *arXiv preprint arXiv:1411.1784*, 2014.
- [38] K. Ouyang, R. Shokri, D. S. Rosenblum, and W. Yang, "A non-parametric generative model for human trajectories," in *Proc. Int. Joint Conf. Artif. Intell. (IJCAI)*, 2018, pp. 3812-3817.
- [39] D. Park and L. R. Rilett, "Forecasting freeway link travel times with a multilayer feedforward neural network," *Computer-Aided Civil and Infrastructure Engineering*, vol. 14, no. 5, pp. 357-367, 1999.
- [40] Y. Ranasinghe, et al., "CrowdDiff: Multi-hypothesis crowd density estimation using diffusion models," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2024.
- [41] D. Rempe, et al., "Controllable pedestrian animation via guided trajectory diffusion," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2023.
- [42] Z. Ruyan and H. Shijun, "The disaster risk assessment of urban storm surges based on the method of fuzzy clustering," in *Proc. 2009 Sixth Int. Conf. Fuzzy Syst. Knowl. Discov.*, vol. 1, 2009, pp. 315-319.
- [43] D. Saxena and J. Cao, "D-gan: Deep generative adversarial nets for spatiotemporal prediction," *arXiv preprint arXiv:1907.08556*, 2019.
- [44] B. Sharchilev, et al., "Finding influential training samples for gradient boosted decision trees," *arXiv preprint arXiv:1802.06640*, 2018.
- [45] R. P. Sheridan, A. Liaw, and M. Tudor, "Light gradient boosting machine as a regression method for quantitative structure-activity relationships," *arXiv preprint arXiv:2105.08626*, 2021.
- [46] X. Shi, Z. Chen, H. Wang, D.-Y. Yeung, W.-K. Wong, and W.-C. Woo, "Convolutional LSTM network: A machine learning approach for precipitation nowcasting," *Advances in Neural Information Processing Systems*, vol. 28, pp. 802-810, 2015.
- [47] G. Sun, S. Wang, L. Zhu, M. Liu, and J. Ma, "GDTS: Goal-guided diffusion model with tree sampling for multi-modal pedestrian trajectory prediction," *arXiv preprint arXiv:2311.14922*, 2024.
- [48] A. Syaputra and E. Laoh, "Customer segmentation on returned product customers using time series clustering analysis," in *Proc. 2020 Int. Conf. ICT Smart Soc. (ICISS)*, 2020, pp. 1-5.

- [49] T. Tiessen, J. Friesen, L. Rausch, and P. F. Pelz, "Using remote sensing data and cluster algorithms to structure cities," in *Proc. 2019 Joint Urban Remote Sens. Event (JURSE)*, 2019, pp. 1-4.
- [50] J. L. Vermeulen, A. Hillebrand, and R. Geraerts, "A comparative study of k-nearest neighbors techniques in crowd simulation," *Computer Animation and Virtual Worlds*, vol. 28, no. 3-4, p. e1775, 2017.
- [51] D. Vihanga, M. Barlow, E. Lakshika, and K. Kasmarik, "Weekly seasonal player population patterns in online games: A time series clustering approach," in *Proc. 2019 IEEE Conf. Games (CoG)*, 2019, pp. 1-8.
- [52] S. Wang, J. Cao, H. Chen, H. Peng, and Z. Huang, "SeqST-GAN: Seq2Seq generative adversarial nets for multi-step urban crowd flow prediction," *ACM Transactions on Spatial Algorithms and Systems (TSAS)*, vol. 6, no. 4, pp. 1-24, 2020.
- [53] W. Wang, G. Lyu, Y. Shi, and X. Liang, "Time series clustering based on dynamic time warping," in *Proc. 2018 IEEE 9th Int. Conf. Softw. Eng. Serv. Sci. (ICSESS)*, 2018, pp. 487-490.
- [54] Z. Wang, Y. Li, J. Wan, and N. Vasconcelos, "Diffusion-based data augmentation for object counting problems," *arXiv preprint arXiv:2401.13992*, 2023.
- [55] M. Yin, M. Sheehan, S. Feygin, J. F. Paiement, and A. Pozdnoukhov, "A generative model of urban activities from cellular data," *IEEE Transactions on Intelligent Transportation Systems*, vol. 19, no. 6, pp. 1682-1696, 2017.
- [56] S. Y. You, Y. D. Wang, L. K. Luo, and H. Peng, "Finding the clusters with potential value in financial time series based on agglomerative hierarchical clustering," in *Proc. 2016 11th Int. Conf. Comput. Sci. Educ. (ICCSE)*, 2016, pp. 77-81.
- [57] H. Yu, X. Chen, Z. Li, G. Zhang, P. Liu, J. Yang, and Y. Yang, "Taxibased mobility demand formulation and prediction using conditional generative adversarial network-driven learning approaches," *IEEE Transactions on Intelligent Transportation Systems*, vol. 20, no. 10, pp. 3888-3899, 2019.
- [58] H. Yuan and W. Lin, "A survey of traffic prediction: from spatio-temporal data to intelligent transportation systems," *Annals of Data Science*, vol. 8, pp. 1-24, 2021.
- [59] C. Zhang, H. Li, X. Wang, and X. Yang, "Cross-scene crowd counting via deep convolutional neural networks," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2015, pp. 833-841.

- [60] J. Zhang, Y. Zheng, D. Qi, R. Li, X. Yi, and T. Li, "Predicting citywide crowd flows using deep spatio-temporal residual networks," *Artificial Intelligence*, vol. 259, pp. 147-166, 2018.
- [61] J. Zhang, J. Liu, and B. Wang, "Spatial cluster based on map algebra," in *Proc. 2010 Int. Conf. E-Bus. E-Gov.*, 2010, pp. 2335-2338.
- [62] Y. Zhang, Y. Li, X. Zhou, X. Kong, and J. Luo, "Curb-GAN: Conditional urban traffic estimation through spatio-temporal generative adversarial networks," in *Proc. 26th ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2020, pp. 842-852.
- [63] Y. Zheng, F. Liu, and H.-P. Hsieh, "U-Air: When urban air quality inference meets big data," in *Proc. 19th ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2013, pp. 1436-1444.
- [64] H. Zhu, Z. Li, Z. Zhang, and H. Lu, "Fine-grained fragment diffusion for cross domain crowd counting," in *Proc. 30th ACM Int. Conf. Multimedia*, 2022, pp. 9665-9674.
- [65] K. Yang, M. Menendez, and S. I. Guler, "Implementing transit signal priority in a connected vehicle environment with and without bus stops," *Transportmetrica B: Transport Dynamics*, vol. 7, no. 1, pp. 423-445, 2019.
- [66] H. Zou, Z. M. Kim, and D. Kang, "A survey of diffusion models in natural language processing," *arXiv preprint arXiv:2305.14671*, 2023.
- [67] "CODiS 氣候觀測資料查詢服務" [Online]. Available: <https://codis.cwa.gov.tw/>
- [68] 鄭佳昇(民 111 年)。基於 3D-RCL 與條件式生成對抗網路產生未來時刻人群分布之可能性探討 (未出版之碩士論文)。國立雲林科技大學，雲林縣。
- [69] 陳昱任(民 110 年)。運用 cGAN 產生未來時刻人流分布(未出版之碩士論文)。國立成功大學，台南市。
- [70] "台灣行政院國情簡介人口" [Online]. Available: <https://www.ey.gov.tw/state/99B2E89521FC31E1/835a4dc2-2c2d-4ee0-9a36-a0629a5de9f0>
- [71] "台灣國家災害防救科技中心氣候變遷風險調適平台" [Online]. Available: <https://dra.ncdr.nat.gov.tw/Frontend/Disaster/ClimateDetail/BAL0000005>
- [72] "臺北小巨蛋-歷年節目查詢" [Online]. Available: <https://www.arena.taipei/News.aspx?n=4A7BFF61FA074F0F&sms=F9A95D3F5A5C2C68/>

- [73] “詹大千(民 107 年 4 月 6 日)。從手機網路訊號資料，探勘人口動態奧妙 (張語辰 & 廖英凱, Eds.)” [Online]. Available:
<https://research.sinica.edu.tw/human-dynamics-chan-ta-chien/>



國立中興大學

NATIONAL CHUNG HSING UNIVERSITY